

**USULAN PENELITIAN S2**

**SISTEM IDENTIFIKASI PEMBICARA OPEN-SET BERBASIS  
ONE-SHOT LEARNING DENGAN MULTI-BACKBONE EMBEDDING  
DAN PEMBARUAN PENGETAHUAN BERTAHAP**



**Oleh :**

**NILAM MUFIDAH**

**24/551986/PPA/06994**

**PROGRAM MAGISTER KECERDASAN ARTIFISIAL  
DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA  
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM  
UNIVERSITAS GADJAH MADA**

**2025**

## HALAMAN PENGESAHAN USULAN PENELITIAN S2

Judul Proposal : Sistem Identifikasi Pembicara Open-Set Berbasis One-Shot  
Learning dengan Multi-Backbone Embedding dan  
Pembaruan Pengetahuan Bertahap

Nama Mahasiswa : Nilam Mufidah

NIM : 24/551986/PPA/06994

Proposal telah diuji pada tanggal 12 Juni 2026 dan sudah diperbaiki sesuai saran  
penguji dan sudah disetujui para penguji.

### Nama Penguji

### Tanda Tangan

- |                                        |    |
|----------------------------------------|----|
| 1. Dr. Dyah Aruming Tyas, S.Si.        | 1. |
| 2. Prof. Drs. Edi Winarko, M.Sc.,Ph.D. | 2. |

Mengetahui,  
Pembimbing 1

Pembimbing 2

Dr.techn. Guntur Budi Herwanto,  
S.Kom., M.Cs.  
NIP. 111199102201607101

Aina Musdholifah, S.Kom.,  
M.Kom. Ph.D  
NIP. 198011122005012002

Yogyakarta, 06 Juli 2026  
Pengusul

Nilam Mufidah  
NIM. 24/551986/PPA/06994

## DAFTAR ISI

|                                                                                      | <b>Halaman</b> |
|--------------------------------------------------------------------------------------|----------------|
| HALAMAN PENGESAHAN USULAN PENELITIAN S2.....                                         | 2              |
| DAFTAR ISI.....                                                                      | 3              |
| DAFTAR GAMBAR.....                                                                   | 4              |
| DAFTAR TABEL.....                                                                    | 4              |
| INTISARI.....                                                                        | 6              |
| BAB I PENDAHULUAN.....                                                               | 1              |
| 1.1 Latar Belakang Masalah.....                                                      | 1              |
| 1.2 Rumusan Masalah.....                                                             | 3              |
| 1.3 Batasan Masalah.....                                                             | 3              |
| 1.4 Tujuan Penelitian.....                                                           | 4              |
| 1.5 Manfaat Penelitian.....                                                          | 4              |
| BAB II TINJAUAN PUSTAKA.....                                                         | 6              |
| BAB III                                                                              |                |
| LANDASAN TEORI.....                                                                  | 12             |
| 3.1 Voice Activity Detection (VAD).....                                              | 12             |
| 3.2 Log-Mel Spectrogram.....                                                         | 13             |
| 3.3 Whisper Encoder.....                                                             | 16             |
| 3.4 ECAPA-TDNN (Emphasized Channel Attention, Propagation and Aggregation TDNN)..... | 17             |
| 3.5 Embedding Fusion.....                                                            | 19             |
| 3.6 Klasifikasi Few-Shot Learning.....                                               | 21             |
| 3.7 Prototypical Network.....                                                        | 23             |
| 3.8 Continual Learning Berbasis Prototype Update.....                                | 25             |
| 3.9 Metrik Evaluasi Performa.....                                                    | 27             |
| BAB IV METODOLOGI PENELITIAN.....                                                    | 29             |
| 4.1 Deskripsi Penelitian.....                                                        | 29             |
| 4.2 Tahapan Penelitian.....                                                          | 32             |
| 4.3 Data.....                                                                        | 34             |
| 4.4 Preprocessing Data.....                                                          | 38             |
| 4.5 Ekstraksi Fitur (Speaker Embedding Extraction).....                              | 39             |
| 4.6 Prototypical Network untuk Identifikasi Pembicara.....                           | 42             |
| 4.7 Pembelajaran Berkelanjutan (Continual Learning).....                             | 45             |
| 4.8 Evaluasi, Validasi, dan Pengujian.....                                           | 48             |
| 4.9 Ablation Study.....                                                              | 49             |
| A. Kontribusi Embedding Fusion terhadap Single Backbone.....                         | 50             |
| B. Kontribusi Continual Learning terhadap Sistem Statis.....                         | 50             |

|                                      |    |
|--------------------------------------|----|
| 4.10 Baseline Comparison.....        | 51 |
| 4.11 Uji Signifikansi Statistik..... | 53 |
| BAB V JADWAL PENELITIAN.....         | 55 |
| DAFTAR PUSTAKA.....                  | 56 |

## DAFTAR GAMBAR

|                              |    |
|------------------------------|----|
| Gambar 4.1 Arsitektur Sistem | 29 |
| Gambar 4.2 Alur Penelitian   | 31 |

## DAFTAR TABEL

|                                                                      |    |
|----------------------------------------------------------------------|----|
| Tabel 2.1 Tinjauan pustaka                                           | 12 |
| Tabel 4.1 Statistik Resmi VoxCeleb1 dan VoxCeleb2                    | 33 |
| Tabel 4.2 Parameter Ekstraksi Log-Mel Spectrogram                    | 36 |
| Tabel 4.3 Konfigurasi Ablation Study — Kontribusi Embedding Fusion   | 43 |
| Tabel 4.4 Konfigurasi Ablation Study — Kontribusi Continual Learning | 44 |
| Tabel 4.5 Baseline Comparison                                        | 45 |
| Tabel 5.1 Jadwal penelitian                                          | 48 |

**INTISARI**  
**SISTEM IDENTIFIKASI PEMBICARA OPEN-SET BERBASIS**  
**ONE-SHOT LEARNING DENGAN MULTI-*BACKBONE EMBEDDING* DAN**  
**PEMBARUAN PENGETAHUAN BERTAHAP**

Oleh  
Nilam Mufidah  
24/551986/PPA/06994

Sistem identifikasi pembicara konvensional umumnya membutuhkan data suara dalam jumlah besar per individu dan bekerja pada skenario *closed-set* yang mengasumsikan seluruh pembicara telah dikenal sebelumnya, sehingga kurang adaptif terhadap penambahan pembicara baru maupun keterbatasan data pelatihan pada kondisi dunia nyata seperti variasi bahasa, kebisingan akustik, dan gaya bicara. Penelitian ini mengembangkan sistem identifikasi pembicara berbasis one-shot learning dengan integrasi multi-*backbone embedding* untuk mengenali individu dari jumlah sampel suara yang sangat terbatas. Sistem ini dirancang untuk menghadapi skenario *open-set identification*, memungkinkan identifikasi pembicara baru sekaligus menjaga akurasi terhadap pembicara yang telah dikenal, serta adaptif terhadap variasi bahasa, kondisi akustik bising, perangkat rekaman, dan gaya bicara. Prosesnya meliputi preprocessing audio, deteksi segmen ucapan menggunakan VAD, agregasi segmen, dan ekstraksi *embedding* melalui model *backbone* modern seperti ECAPA-TDNN dan Whisper *encoder* untuk menghasilkan representasi suara yang diskriminatif dan stabil.

*Embedding* yang dihasilkan digunakan dalam prototypical network untuk melakukan identifikasi berbasis jarak terhadap prototype pembicara. Sistem menandai *input* sebagai known speaker jika jaraknya dekat dengan prototype, atau unknown speaker jika jauh, sehingga mendukung open-set scenario. Mekanisme continual learning berbasis pembaruan prototype memungkinkan penambahan dan adaptasi pembicara baru secara inkremental tanpa pelatihan ulang penuh, mengurangi risiko *catastrophic forgetting*. Dengan kombinasi metode ini, sistem diharapkan efisien, adaptif, dan robust, dengan performa diukur melalui metrik akurasi, EER, *average accuracy*, dan forgetting measure untuk evaluasi jangka panjang.

**Kata Kunci:** *Identifikasi Pembicara, One-Shot Learning, Multi-Backbone Embedding, Open-Set Identification, Continual Learning, Prototypical Network, Voice Activity Detection*

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang Masalah

Identifikasi pembicara merupakan salah satu komponen penting dalam pengembangan sistem interaksi manusia dan mesin, autentikasi biometrik, serta berbagai sistem keamanan cerdas berbasis suara. Dalam implementasi konvensional, sistem identifikasi pembicara umumnya memerlukan sejumlah besar data suara dari setiap individu agar dapat mencapai akurasi yang tinggi. Kebutuhan data yang besar ini menjadi kendala ketika sistem diterapkan pada lingkungan nyata yang dinamis, di mana pengguna baru sering kali hanya tersedia dalam jumlah rekaman yang sangat terbatas atau bahkan hanya satu kali interaksi awal (Kinnunen & Li, 2010; Wan et al., 2018).

Seiring berkembangnya teknologi pembelajaran mesin, pendekatan one-shot dan few-shot learning mulai digunakan untuk mengatasi keterbatasan tersebut. Pendekatan ini memungkinkan sistem mengenali pembicara baru hanya dari satu atau beberapa contoh rekaman suara dengan memanfaatkan representasi *embedding* yang bersifat diskriminatif. Arsitektur seperti Siamese Network dan Prototypical Network memungkinkan identifikasi dilakukan berdasarkan kesamaan representasi fitur, bukan sekadar klasifikasi konvensional, sehingga sistem dapat beradaptasi lebih cepat terhadap pembicara baru dengan data minimal (Koch et al., 2015; Snell et al., 2017). Perkembangan terbaru menunjukkan bahwa pendekatan few-shot semakin efektif ketika dikombinasikan dengan *backbone embedding* modern seperti ECAPA-TDNN maupun model berbasis transformer yang mampu menghasilkan representasi speaker yang lebih robust terhadap variasi bahasa dan kondisi akustik.

Selain kemampuan mengenali pembicara baru dari data terbatas, sistem identifikasi pembicara di dunia nyata juga dihadapkan pada kebutuhan untuk terus menambahkan pengguna baru tanpa perlu melakukan pelatihan ulang secara menyeluruh. Permasalahan ini berkaitan dengan paradigma continual learning, di mana model perlu mempelajari informasi baru tanpa kehilangan kemampuan

mengenali data yang telah dipelajari sebelumnya (Parisi et al., 2019). Tantangan utama pada pendekatan ini adalah catastrophic forgetting, yaitu kondisi ketika model kehilangan performa pada data lama setelah diperbarui menggunakan data baru (French, 1999). Berbagai strategi telah dikembangkan untuk mengurangi dampak tersebut, seperti replay *buffer* dan regularisasi parameter melalui metode seperti Elastic Weight Consolidation (Kirkpatrick et al., 2017; Rolnick et al., 2019). Namun, dalam sistem identifikasi pembicara berbasis *embedding*, pendekatan yang lebih ringan dan efisien dapat dilakukan melalui pembaruan prototype speaker secara bertahap tanpa memerlukan pelatihan ulang keseluruhan model, sehingga sistem dapat menyesuaikan representasi pembicara secara inkremental.

Selain aspek pembelajaran model, tantangan lain pada implementasi sistem identifikasi pembicara di dunia nyata adalah kebutuhan untuk mengekstraksi segmen ucapan secara otomatis dari aliran audio yang panjang dan penuh gangguan. Dalam berbagai aplikasi seperti robot layanan, asisten virtual, maupun sistem kontrol berbasis suara, sistem perlu mendeteksi bagian ucapan yang relevan tanpa intervensi manual, meskipun kondisi lingkungan mengandung kebisingan latar atau ucapan yang sangat singkat. Oleh karena itu, komponen Voice Activity Detection (VAD) menjadi penting untuk memisahkan segmen ucapan dari keheningan atau noise. Pendekatan VAD modern berbasis deep learning terbukti lebih tangguh dibanding metode konvensional berbasis energi atau ambang frekuensi, terutama pada lingkungan akustik yang kompleks dan dinamis.

Berdasarkan berbagai perkembangan dan tantangan tersebut, penelitian ini mengusulkan pengembangan sistem identifikasi pembicara berbasis pendekatan one-shot learning dengan integrasi multi-*backbone embedding* yang mampu bekerja dalam skenario open-set serta mendukung pembaruan pengetahuan secara bertahap. Sistem yang diusulkan memanfaatkan ekstraksi *embedding* menggunakan *backbone* modern, segmentasi ucapan melalui Voice Activity Detection, serta mekanisme prototypical classification untuk menentukan identitas pembicara berdasarkan kedekatan representasi *embedding* terhadap prototype

speaker yang tersimpan. Selanjutnya, prototype speaker diperbarui secara inkremental ketika data baru tersedia, sehingga sistem mampu menambahkan pembicara baru maupun memperkaya representasi pembicara lama tanpa mengorbankan performa sebelumnya. Dengan pendekatan ini, sistem diharapkan mampu menghasilkan solusi identifikasi pembicara yang adaptif, efisien, dan robust untuk penggunaan di lingkungan nyata dengan ketersediaan data yang terbatas serta kebutuhan penambahan pengguna secara dinamis.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, rumusan masalah dalam penelitian ini berfokus pada keterbatasan sistem identifikasi pembicara dalam mengenali individu hanya dari satu sampel suara (*one-shot*) dengan tetap mempertahankan akurasi tinggi pada kondisi yang penuh gangguan, seperti kebisingan latar, gema, serta variasi intonasi dan gaya bicara. Permasalahan ini mencangkup kebutuhan akan mekanisme *Voice Activity Detection (VAD)* yang adaptif terhadap dinamika percakapan alami, serta integrasi pembelajaran berkelanjutan (*continue learning*) yang memungkinkan penambahan pembicara baru tanpa menurunkan kinerja terhadap pembicara yang telah dikenali, serta kemampuan sistem dalam mengenali individu yang secara nyata bukan bagian dari individu yang telah terdaftar. Pada banyak kasus, individu yang tidak di kenal justru di kategorikan ke dalam individu yang sudah ada karena sistem cenderung memaksa proses identifikasi ke kelas yang tersedia. Kondisi ini menunjukkan perlunya mekanisme *open-set identification* yang mampu membedakan antara individu yang terdaftar dan individu baru secara lebih akurat.

## 1.3 Batasan Masalah

Batasan masalah pada penelitian ini adalah sebagai berikut.

1. Pengujian sistem difokuskan pada lingkungan yang bersifat umum, seperti area rumah, kantor, kafe, atau ruang publik semi-terbuka, dengan tingkat kebisingan yang masih dalam rentang wajar; tidak mencakup pengujian

pada kondisi ekstrem seperti lingkungan industri berat atau situasi akustik yang ekstrem.

2. Sistem *Voice Activity Detection* (VAD) yang dikembangkan hanya difokuskan pada segmentasi ucapan secara kontekstual dengan mempertimbangkan informasi temporal dan linguistik dasar, tanpa menangani secara menyeluruh percakapan tumpang tindih (*overlapping speech*).
3. Evaluasi sistem dilakukan menggunakan dataset publik VoxCeleb1 dan VoxCeleb2.
4. Penelitian ini tidak membahas penggunaan dataset berskala besar secara penuh maupun data yang bersifat multi bahasa secara mendalam.

#### 1.4 Tujuan Penelitian

Tujuan dari penelitian ini adalah untuk mengembangkan sistem identifikasi pembicara berbasis pendekatan *one-shot* yang mampu mengenali individu hanya dari satu sampel suara dengan tingkat akurasi yang tinggi dan dalam kondisi lingkungan yang penuh gangguan seperti kebisingan latar, gema, serta variasi intonasi dan gaya bicara. Penelitian ini juga bertujuan untuk mengintegrasikan mekanisme *Voice Activity Detection* (VAD) yang adaptif dan kontekstual terhadap dinamika percakapan alami sehingga proses ekstraksi suara pembicara menjadi lebih akurat. Selain itu, penelitian ditujukan untuk menerapkan pendekatan pembelajaran berkelanjutan (*continue learning*) agar sistem mampu menambahkan pembicara baru secara dinamis tanpa menurunkan kinerja terhadap pembicara yang telah dikenali sebelumnya. Penelitian ini juga bertujuan untuk mengembangkan mekanisme *open-set identification* agar sistem dapat membedakan pembicara terdaftar dengan pembicara yang belum pernah didaftarkan, sehingga tidak terjadi pemaksaan identifikasi ke dalam kategori pengguna yang sudah ada.

#### 1.5 Manfaat Penelitian

Manfaat dari penelitian ini adalah meningkatkan kinerja sistem identifikasi pembicara dalam kondisi yang terjadi gangguan seperti kebisingan latar, gema,

serta variasi intonasi dan gaya bicara, melalui pendekatan *one-shot learning* yang memungkinkan pengenalan individu hanya dari satu sampel suara dengan tetap mempertahankan akurasi yang tinggi. Sistem yang dikembangkan diharapkan mampu melakukan segmentasi ucapan lebih akurat melalui mekanisme *Voice Activity Detection (VAD)* yang adaptif dan kontekstual terhadap dinamika percakapan alami. Selain itu, penerapan pembelajaran berkelanjutan (*continual learning*) memberikan manfaat dalam memungkinkan penambahan pembicara baru secara dinamis tanpa menurunkan kinerja terhadap pembicara yang telah dikenali sebelumnya. Penelitian ini juga memberikan kontribusi dalam pengembangan mekanisme open-set identifikasi, sehingga sistem mampu membedakan pembicara terdaftar dan pembicara yang belum didaftarkan, serta menghindari kesalahan identifikasi akibat pemaksaan klasifikasi ke dalam kategori yang sudah ada. Secara keseluruhan, hasil penelitian ini diharapkan dapat berkontribusi pada pengembangan teknologi identifikasi pembicara yang lebih andal dan adaptif untuk diterapkan pada berbagai sistem cerdas berbasis suara.

## BAB II

### TINJAUAN PUSTAKA

Perkembangan sistem identifikasi pembicara dalam beberapa tahun terakhir menunjukkan tren yang jelas menuju penggunaan *backbone embedding* yang kuat dan robust, dikombinasikan dengan strategi *few-shot learning* dan *open-set identification*. Penelitian yang dilakukan oleh Li et al. (2023) memperkenalkan *few-shot speaker identification* menggunakan *lightweight prototypical network* dengan *feature* grouping dan *feature* interaction. Metode ini memungkinkan sistem membangun *embedding representatif* dari jumlah sampel yang sangat terbatas, sehingga cocok untuk skenario *one-shot* dan menunjukkan efisiensi komputasi tinggi. Penelitian oleh Wang et al. (2023) juga menunjukkan pendekatan serupa dengan menggabungkan ECAPA-TDNN sebagai *feature extractor* dan strategi *episodic meta-learning* untuk *short utterance speaker verification*, sehingga meningkatkan kemampuan model mengenali pembicara baru dengan data minimal.

Penelitian identifikasi pembicara juga berkembang pada skenario perangkat bersama (*shared-device*) atau rumah tangga (*household*), di mana beberapa pembicara dengan karakteristik suara mirip menggunakan satu perangkat yang sama. Foggia et al. (2023) mengusulkan sistem re-identifikasi pembicara *few-shot* untuk robot sosial berbasis *ResNet34* dengan *Temporal Average Pooling*, di mana setiap pembicara direpresentasikan oleh tiga prototype sekaligus disertai mekanisme threshold penolakan untuk skenario *open-set*. Pendekatan berbasis adaptasi *embedding* juga diusulkan oleh Tan et al. (2021), yang memperkenalkan *household-adapted nonlinear mapping* untuk melengkapi *scoring* global antar-*embedding*, berhasil menurunkan Equal Error Rate (EER) hingga 45 - 71% pada household simulasi dan 49,2% pada data dunia nyata. Sebagai pengembangan lanjutan, Kishan et al. (2022) mengusulkan openFEAT, yang memanfaatkan arsitektur Transformer berbasis *set-to-set function* untuk mengadaptasi ruang *embedding* universal menjadi ruang *embedding* spesifik-household, secara eksplisit dirumuskan sebagai tugas *few-shot open-set*

*recognition*, dan berhasil menurunkan identification EER hingga 23 - 31% relatif dibanding metode sebelumnya. Ketiga penelitian tersebut menegaskan pentingnya adaptasi *embedding* terhadap subset pembicara spesifik dalam skenario dunia nyata, namun belum mengintegrasikan mekanisme *continual learning* berbasis pembaruan prototype secara eksplisit sebuah celah yang menjadi fokus utama penelitian ini.

Selain *prototypical network*, penelitian oleh Chaubey et al. (2022) menyoroti penggunaan *relation network* yang digabungkan dengan pelatihan episodik. Pendekatan ini mengevaluasi hubungan antar-*embedding* secara langsung, sehingga meningkatkan performa pada skenario *few-shot* dan *open-set*. Pendekatan lain menekankan pentingnya robustness terhadap noise dan kondisi dunia nyata, seperti yang diperlihatkan oleh Chen et al. (2024) melalui integrasi *WavLM pretrained* dengan *Speaker Reciprocal Points* dan pembelajaran sampel negatif. Strategi ini memungkinkan sistem menolak pembicara yang tidak dikenal sekaligus menjaga akurasi tinggi, menutup gap yang sebelumnya muncul pada sistem berbasis *x-vector* atau ECAPA-TDNN tradisional.

Seiring munculnya foundation models berbasis transformer, penelitian terbaru memperlihatkan kemampuan luar biasa dalam menghasilkan *embedding* speaker yang diskriminatif dan robust. Emon et al. (2025) memperkenalkan *Whisper Speaker Identification (Whisper-SI)* yang memanfaatkan *encoder* dari model *ASR multilingual Whisper* untuk membangun *embedding* speaker tahan terhadap variasi bahasa dan kondisi akustik. Model ini menunjukkan peningkatan performa signifikan dibanding *ECAPA-TDNN* dan *x-vector* pada *dataset* multilingual, khususnya untuk *open-set* dan *few-shot speaker identification*. Selanjutnya, Zhao et al. (2024) mengembangkan *Whisper-PMFA*, yang menambahkan *multi-scale feature aggregation* pada *Whisper* untuk menangkap representasi speaker dari berbagai level, menurunkan *EER* pada *benchmark VoxCeleb1* dibanding *baseline* klasik. Pendekatan serupa ditunjukkan oleh Zhang et al. (2024) melalui *Whisper-SV*, yang menggunakan *multi-layer aggregation* dan *attention adaptor*, menghasilkan *embedding* kompetitif meski jumlah sampel

terbatas, sehingga memperkuat strategi *one-shot/few-shot* dan *open-set identification*.

Selain *backbone* modern, aspek *continual learning* menjadi penting untuk sistem speaker identification yang adaptif. Penelitian oleh Wang et al. (2025) memperkenalkan *framework gated fusion layer* untuk *continual learning* pada tugas audio, yang menjaga representasi lama sambil menambahkan informasi speaker baru. Pendekatan ini memungkinkan model belajar secara bertahap tanpa kehilangan performa pada speaker sebelumnya, sehingga mendukung integrasi *one-shot/few-shot learning* dengan update model incremental di dunia nyata.

*Arsitektur fusion* juga terbukti meningkatkan performa *embedding* speaker. Penelitian oleh Novotný et al. (2025) mengusulkan CRET, yang memadukan Conv2D, ResNet, dan ECAPA-TDNN, menunjukkan bahwa penggabungan multi-level representasi temporal dan spektral dapat meningkatkan performa dibanding *baseline* tunggal. Selain itu, penelitian oleh Jung et al. (2024) memperkenalkan *toolkit ESPnet-SPK*, yang mendukung *reproducibility* dan eksperimen cepat, sehingga memudahkan evaluasi sistem *few-shot* maupun verification secara konsisten.

Dasar-dasar penelitian sebelumnya yang menjadi tinjauan pustaka pada penelitian ini dirangkum dalam Tabel 2.1.

**Tabel 2.1** Tinjauan pustaka

| <b>Nama</b>      | <b>Penelitian</b>                                                                                                   | <b>Metode</b>                                                               | <b>Dataset</b>                      | <b>Hasil</b>                                                                                                                                                                                                                   |
|------------------|---------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|-------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Li et al. (2023) | Few-Shot Speaker Identification Using Lightweight Prototypical Network with <i>Feature Grouping and Interaction</i> | Lightweight prototypical network, <i>feature grouping &amp; interaction</i> | VoxCeleb 1, VoxCeleb 2, LibriSpeech | Pendekatan ini menunjukkan kinerja pada identifikasi pembicara dengan data terbatas, mencapai akurasi 85-88% pada 5-shot scenario, sekaligus menjaga efisiensi komputasi dan representasi <i>embedding</i> yang diskriminatif. |

|                      |                                                                                                              |                                                                                                                                                                       |                                                                                                  |                                                                                                                                                                                                                                                                  |
|----------------------|--------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Foggia et al. (2023) | Few-Shot Re-Identification of the Speaker by Social Robots                                                   | ResNet34 + Temporal Average <i>Pooling</i> , multi-prototype (3/speaker), threshold open-set                                                                          | VoxCeleb1, SpReW (custom)                                                                        | Sistem re-identifikasi pembicara few-shot untuk robot sosial menunjukkan akurasi re-identifikasi tinggi, dievaluasi terhadap jumlah sampel per speaker, jumlah speaker dikenal, dan durasi sampel suara; dilengkapi mekanisme penolakan untuk skenario open-set. |
| Tan et al. (2021)    | Improving Speaker Identification for Shared Devices by Adapting <i>Embeddings</i> to Speaker Subsets         | Household-adapted nonlinear <i>mapping</i> melengkapi <i>scoring</i> global antar- <i>embedding</i> , dioptimalkan dengan <i>input dropout</i>                        | Household simulasi berbasis VoxCeleb (2-7 speaker/rumah tangga), data internal <i>real-world</i> | Equal Error Rate (EER) berkurang 45-71% pada household simulasi dan 49,2% pada data <i>real-world</i> dibanding <i>scoring</i> global tanpa adaptasi.                                                                                                            |
| Kishan et al. (2022) | openFEAT: Improving Speaker Identification by Open-Set Few-Shot <i>Embedding</i> Adaptation with Transformer | Transformer berbasis set-to-set function untuk adaptasi ruang <i>embedding</i> universal menjadi spesifik-household, dirumuskan sebagai few-shot open-set recognition | Household simulasi berbasis VoxCeleb (2-7 speaker/rumah tangga)                                  | Identification EER (IEER) berkurang 23-31% relatif dibanding metode sebelumnya, termasuk dibanding Tan et al. (2021).                                                                                                                                            |
| Wang et al. (2023)   | Few-shot Short Utterance Speaker Verification using Meta-Learning with ECAPA-TDNN <i>Embedding</i>           | ECAPA-TDNN + prototypical network + episodic/meta-learning                                                                                                            | VoxCeleb1, VoxCeleb2                                                                             | Model yang menggabungkan ECAPA-TDNN dan meta-learning berhasil meningkatkan kemampuan verifikasi speaker pendek, dengan EER 6,2%, mengungguli <i>baseline</i> ECAPA-TDNN tanpa episodic <i>training</i> .                                                        |

|                       |                                                                                                             |                                                              |                                         |                                                                                                                                                                                                                                                   |
|-----------------------|-------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------|-----------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Chaubey et al. (2022) | Improved Relation Networks for <i>End-to-End</i> Speaker Verification and Identification                    | Relation Network + episodic <i>training</i>                  | VoxCeleb1                               | Relation network berbasis meta-learning mampu menangkap hubungan antar <i>embedding</i> secara langsung, menghasilkan EER 5,9% pada speaker verification dan meningkatkan performa few-shot speaker identification dibandingkan <i>baseline</i> . |
| Chen et al. (2022)    | WavLM: Large-Scale Self-Supervised Pretraining for Robust Speech Representation                             | WavLM (self-supervised)                                      | LibriSpeech, WSJ, noisy <i>datasets</i> | Model WavLM mampu menghasilkan representasi audio yang robust terhadap variasi akustik dan noise, dengan peningkatan akurasi verifikasi speaker sebesar 2-3% dibandingkan <i>baseline</i> supervised tradisional.                                 |
| Emon et al., 2025     | Whisper Speaker Identification (Whisper-SI)                                                                 | Transformer foundation model (Whisper)                       | Voxtube, JVS                            | Performa lebih baik dibanding ECAPA-TDNN dan x-vector pada skenario open-set dan few-shot; model menunjukkan penurunan EER yang signifikan.                                                                                                       |
| Zhao et al., 2024     | Whisper-PMF A: Partial Multi-Scale <i>Feature</i> Aggregation for Speaker Verification using Whisper Models | Transformer Whisper + <i>multi-scale feature aggregation</i> | VoxCeleb1, CN-Celeb1                    | Sistem mencapai EER 1.42% (VoxCeleb1) dan 8.23% (CN-Celeb1); ini merupakan penurunan 0.58% dan 1.81% absolut dibanding ECAPA-TDNN pada kedua <i>dataset</i> .                                                                                     |
| Zhang et al., 2024    | Whisper-SV: Adapting Whisper for Low-data-resource Speaker Verification                                     | Multi-layer aggregation + <i>attention</i>                   | VoxCeleb1, FFSVC, IMSV                  | Sistem mencapai EER 2.22% / minDCF 0.307 (VoxCeleb1), EER 6.14% / minDCF 0.488 (FFSVC), EER 7.50% / minDCF 0.582 (IMSV), memperlihatkan performa kompetitif pada kondisi data terbatas.                                                           |

|                       |                                                                                             |                                                                                               |            |                                                                                                                                                                                                       |
|-----------------------|---------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------|------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Wang et al., 2025     | Continual Speech Learning with Fused Speech <i>Features</i>                                 | <i>Continual learning</i> melalui gated fusion <i>layer</i> terintegrasi dengan model Whisper |            | Model meningkatkan <i>accuracy</i> dan retensi performa pada berbagai tugas speech dibanding metode <i>continual learning</i> konvensional, menunjukkan kemampuan adaptasi tanpa forgetting.          |
| Novotný et al. (2021) | Knowledge Distillation for Efficient Speaker <i>Embeddings</i>                              | Knowledge distillation                                                                        | VoxCeleb 1 | Knowledge distillation memungkinkan transfer kemampuan model besar ke model ringan, sehingga student model mempertahankan sekitar 95% performa teacher model dengan efisiensi komputasi lebih tinggi. |
| Jung et al., 2024     | ESPnet-SPK: full <i>pipeline</i> speaker <i>embedding toolkit</i> with reproducible recipes | <i>Toolkit</i> dengan pre-trained & self-supervised front-ends                                | Vox1-O     | <i>Toolkit</i> ESPnet-SPK dengan WavLM-Large + ECAPA-TDNN menghasilkan EER 0.39% pada Vox1-O, menjadi <i>baseline</i> kuat untuk banyak eksperimen speaker <i>embedding</i> .                         |

## BAB III

### LANDASAN TEORI

#### 3.1 *Voice Activity Detection (VAD)*

*Voice Activity Detection (VAD)* berbasis deep learning dirancang untuk membedakan ucapan dari keheningan atau noise, dan tantangan utamanya adalah mempertahankan akurasi pada kondisi bising sekaligus menjaga latensi rendah untuk aplikasi *real-time*. Menurut Larsen, Koch, dan Tan (2022), pendekatan VAD tradisional berbasis threshold energi sangat rentan terhadap perubahan SNR, sehingga mereka mengusulkan arsitektur waveform-based adversarial multi-task VAD yang secara eksplisit memodelkan ketahanan terhadap noise melalui mekanisme pembelajaran adversarial (adversarial learning) (Larsen et al. 2022). Model ini memproses raw waveform sebagai *input*, yang memungkinkan jaringan mempelajari representasi temporal yang lebih kaya dibandingkan fitur konvensional berbasis spektrum. Dalam arsitektur tersebut, selain jaringan utama untuk klasifikasi voice/non-voice, peneliti menambahkan jaringan diskriminator yang bertugas mengklasifikasikan jenis noise, sehingga menghasilkan skema multi-task yang memperkuat generalisasi model pada berbagai lingkungan akustik.

Pelatihan dilakukan menggunakan prinsip adversarial *training*, di mana jaringan utama (*feature encoder* + VAD classifier) dilatih untuk menipu diskriminator agar tidak mampu membedakan tipe noise. Secara matematis, proses ini diformulasikan melalui loss adversarial multi-task, yaitu:

$$L = L_{VAD} - \lambda L_{disc} \quad (3.1)$$

dengan :

$L_{VAD}$  = Loss klasifikasi voice vs non-voice (binary cross-entropy),

$L_{disc}$  = Loss klasifikasi noise (multi-class cross-entropy),

$\lambda$  = Koefisien yang mengontrol kekuatan sinyal adversarial.

Loss klasifikasi utama dituliskan sebagai:

$$L_{VAD} = - [y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})] \quad (3.2)$$

Sedangkan loss diskriminator untuk K jenis noise adalah:

$$L_{disc} = - \sum_{k=1}^K t_k \log(\hat{t}_k) \quad (3.3)$$

Pada tahap backpropagation, gradien dari  $-\lambda L_{disc}$  dibalik melalui *gradient reversal layer* (GRL), sehingga *encoder* berusaha meminimalkan kemampuan diskriminator, menghasilkan fitur yang invariant terhadap noise. Larsen et al. (2022) menyatakan bahwa mekanisme ini secara signifikan meningkatkan ketahanan VAD pada kondisi SNR rendah hingga >10 dB dibanding *baseline* tanpa adversarial.

Selain itu, model dirancang untuk memiliki latensi sangat rendah, yang dikenal sebagai *algorithmic delay*. Delay ini bergantung pada ukuran kernel konvolusi dan panjang konteks temporal yang digunakan pada arsitektur CNN. Secara umum, delay dapat dihitung sebagai:

$$Delay = \sum_{i=1}^N \left( \frac{k_i - 1}{2} \right) \frac{1}{f_n} \quad (3.4)$$

dimana:

$k_i$  = ukuran *layer* ke-i,

$N$  = jumlah *layer* konvolusi,

$f_n$  = *sampling rate*

Larsen et al. melaporkan bahwa ketika delay dikurangi dari 398 ms menjadi hanya 23 ms, performa hanya berkurang sedikit, menunjukkan bahwa arsitektur tetap efektif untuk kebutuhan *real-time*. Evaluasi performa menggunakan metrik Area Under Curve (AUC) pada ROC, dan hasil menunjukkan bahwa adversarial multi-task memberikan peningkatan AUC yang signifikan terutama pada SNR rendah, menegaskan efektivitas teori representasi invarian noise dalam task VAD.

### 3.2 Log-Mel Spectrogram

*Log-Mel Spectrogram* merupakan representasi sinyal audio dalam domain frekuensi-waktu yang banyak digunakan dalam pengolahan suara digital, khususnya pada aplikasi pengenalan suara (*speech recognition*) dan identifikasi

pembicara karena mampu memuat ciri akustik yang relevan secara efisien. Representasi ini dibangun dari spektrum energi sinyal audio dengan mempertimbangkan karakteristik persepsi pendengaran manusia sehingga informasi frekuensi yang penting secara akustik dapat diekstraksi secara lebih efektif oleh model pembelajaran mesin. Representasi frekuensi-waktu ini sangat penting dalam konteks pembelajaran mendalam karena memetakan struktur spektral suara yang berubah sepanjang waktu ke dalam bentuk yang dapat diproses oleh model seperti konvolusional maupun transformer (McLoughlin, 2026).

Proses pembentukan *Log-Mel Spectrogram* dimulai dengan menerapkan *Short-Time Fourier Transform* (STFT) terhadap sinyal audio yang telah dinormalisasi, sehingga menghasilkan spektrum frekuensi pada setiap jendela waktu pendek. STFT membagi sinyal audio menjadi sejumlah frame dengan panjang waktu tertentu, kemudian melakukan transformasi Fourier pada setiap frame untuk memperoleh representasi frekuensi-waktu. Representasi inilah yang menjadi dasar awal untuk mengekstraksi informasi frekuensi dari sinyal suara (McLoughlin, 2026).

Spektrum frekuensi hasil STFT kemudian dipetakan ke skala *Mel*, yakni skala frekuensi non-linier yang dirancang untuk mendekati cara telinga manusia memandang perbedaan pitch (tinggi-rendahnya suara). Skala *Mel* menggambarkan bahwa perubahan kecil pada frekuensi rendah lebih mudah terdengar oleh manusia daripada perubahan sebanding pada frekuensi tinggi. Oleh karena itu, penggunaan skala *Mel* dalam representasi spektrum audio memungkinkan model memfokuskan perhatian pada komponen frekuensi yang lebih relevan terhadap persepsi manusia, yang sangat penting terutama dalam konteks pengenalan suara dan identifikasi pembicara. Konversi dari frekuensi linier (Hz) ke skala *Mel* sering dilakukan menggunakan hubungan empiris:

$$m = 2595 \log\left(1 + \frac{f}{700}\right) \quad (3.5)$$

di mana  $m$  adalah frekuensi dalam satuan *Mel* dan  $f$  adalah frekuensi dalam Hertz. Persamaan ini banyak digunakan dalam literatur pengolahan suara sebagai

pendekatan untuk menyelaraskan representasi frekuensi dengan respons persepsi auditorik manusia (O'Shaughnessy, 1987).

Setelah spektrum frekuensi dipetakan ke *Mel filter banks*, tahap berikutnya adalah menghitung logaritma dari energi pada setiap *Mel band*. Transformasi logaritmik ini dimaksudkan untuk menekan rentang dinamis energi spektral dan menyesuaikannya dengan sensitivitas telinga manusia, yang bersifat logaritmik terhadap amplitudo suara. Representasi *Log-Mel Spectrogram* yang diperoleh kemudian menjadi masukan yang efektif bagi model pembelajaran mendalam karena memuat fitur-fitur frekuensi yang informatif, kompak, dan lebih sesuai dengan persepsi akustik manusia dibandingkan representasi spektrum linier biasa. Representasi ini meningkatkan kemampuan model dalam menangkap pola suara yang berbeda antar pembicara maupun variasi fonetik dalam *speech recognition* (McLoughlin, 2026).

Parameter desain seperti jumlah *Mel filter banks*, ukuran jendela (*window size*), dan tingkat tumpang tindih (*hop length*) sering kali dioptimalkan dalam penelitian untuk memperoleh performa ekstraksi fitur yang optimal pada berbagai kondisi perekaman suara. Optimalisasi parameter-parameter ini penting untuk menyeimbangkan resolusi frekuensi-waktu dan efisiensi komputasi, khususnya ketika digunakan sebagai *input* pada model berbasis deep learning dalam aplikasi klasifikasi suara atau identifikasi pembicara (McLoughlin, 2026).

Pada penelitian ini, parameter *Log-Mel Spectrogram* ditetapkan mengikuti konfigurasi yang umum digunakan pada penelitian identifikasi pembicara berbasis ECAPA-TDNN maupun Whisper, yaitu frekuensi pencuplikan (*sample rate*) sebesar 16 kHz, jumlah filter Mel sebanyak 80 buah, ukuran jendela (*window size*) 25 milidetik, dan *hop length* 10 milidetik, dengan fungsi jendela *Hamming* pada ECAPA-TDNN dan fungsi jendela *Hann* pada Whisper (Desplanques et al., 2020; Radford et al., 2022). Kesamaan konfigurasi antara kedua *backbone* ini memungkinkan penggunaan satu jalur (*pipeline*) ekstraksi *Log-Mel Spectrogram* yang seragam sebagai *front-end* bersama, sehingga menyederhanakan arsitektur sistem *multi-backbone* yang diusulkan.

### 3.3 *Whisper Encoder*

Whisper merupakan salah satu model *automatic speech recognition* (ASR) yang dibangun dengan arsitektur *encoder-decoder* berbasis *Transformer* yang telah digunakan secara luas dalam penelitian pengenalan suara karena kemampuannya untuk menangani variasi bahasa dan kondisi perekaman yang beragam (Polat et al., 2024). Model ini menangani pemrosesan sinyal audio secara end-to-end dari *input* representasi spektral audio hingga *output* teks tanpa perlu memisahkan komponen model akustik dan bahasa secara terpisah, sehingga menyederhanakan *pipeline* pelatihan dan *inference* dibandingkan metode klasik seperti HMM-NN hybrid (Polat et al., 2024).

Proses *feature extraction* pada *Whisper* dimulai dengan transformasi sinyal audio mentah menjadi *log-magnitude Mel spectrogram*. Secara teknis, sinyal audio direpresentasikan menjadi spektrogram yang mencerminkan distribusi energi frekuensi terhadap waktu pada skala Mel. Suatu skala frekuensi non-linier yang mendekati persepsi pendengaran manusia. Kemudian diambil logaritmanya untuk menekan dinamika rentang energi. Representasi ini memungkinkan model untuk lebih sensitif terhadap fitur akustik penting yang relevan terhadap fonetik dan karakter suara, sekaligus meminimalkan efek noise atau variasi amplitudo yang tidak informatif.

Representasi *log-Mel spectrogram* ini kemudian diproses oleh *encoder Transformer* yang biasanya terdiri dari lapisan konvolusional awal (*convolutional front-end*) diikuti oleh beberapa blok *multi-head self-attention*. Lapisan konvolusional digunakan untuk menangkap representasi lokal dalam domain waktu-frekuensi dan mereduksi dimensi awal, sehingga memudahkan jaringan *Transformer* untuk fokus pada pola berskala lebih besar. Selanjutnya, mekanisme *self-attention* memungkinkan model untuk menimbang hubungan antar posisi sinyal secara global, sehingga konteks temporal dan spektral keseluruhan dapat dipahami sekaligus tanpa pemrosesan sekuensial seperti yang terjadi pada RNN atau LSTM. Hal ini memungkinkan *encoder* untuk menghasilkan representasi fitur audio yang kaya dan berdimensi tinggi yang mencerminkan karakteristik suara secara komprehensif.

Selain itu, *Whisper* dilatih secara *multilingual* pada *dataset* audio besar untuk tugas ASR, termasuk ratusan ribu jam data suara dalam berbagai bahasa. Latin data inilah yang membekali *encoder* dengan kemampuan generalisasi terhadap variasi bahasa, aksen, dan noise lingkungan, yang dalam banyak penelitian telah dibuktikan memberikan performa robust dalam tugas pengenalan suara lintas bahasa dan kondisi perekaman yang berbeda (Polat et al., 2024).

Dalam konteks ekstraksi *speaker embedding*, representasi internal yang dihasilkan oleh *encoder Whisper* dapat dimanfaatkan sebagai fitur diskriminatif untuk membedakan pembicara. Representasi ini mencakup informasi yang cukup kaya tentang karakteristik suara individu, sehingga mampu memberi performa identifikasi speaker yang kompetitif, bahkan ketika diaplikasikan pada *dataset* multibahasa dan kondisi dunia nyata. Pendekatan ini selaras dengan tren penelitian modern yang memanfaatkan model ASR berbasis Transformer sebagai basis *feature extractor* bukan hanya untuk transkripsi, tetapi juga untuk tugas-tugas lain seperti *speaker verification* atau pengenalan emosi suara melalui *embedding* yang dihasilkan (Wang et al., 2025).

### 3.4 ECAPA-TDNN (Emphasized Channel Attention, Propagation and Aggregation TDNN)

Ekstraksi fitur merupakan tahap krusial dalam sistem identifikasi pembicara karena bertujuan mengubah sinyal suara mentah menjadi representasi numerik berdimensi tetap yang mampu merepresentasikan karakteristik unik seorang pembicara, yang dikenal sebagai *speaker embedding*. Representasi ini harus bersifat diskriminatif antar pembicara sekaligus robust terhadap variasi non-identitas seperti noise, durasi ucapan, dan perbedaan kanal perekaman (Snyder et al., 2018).

Pendekatan modern dalam ekstraksi *speaker embedding* banyak menggunakan jaringan saraf dalam (deep neural networks) berbasis *Time Delay Neural Network (TDNN)*. Salah satu arsitektur *state-of-the-art* adalah ECAPA-TDNN (*Emphasized Channel Attention, Propagation and Aggregation TDNN*) yang diperkenalkan oleh Desplanques et al. (2020). Model ini merupakan

pengembangan TDNN konvensional dengan inovasi yang memungkinkan representasi fitur temporal multi-skala yang lebih kaya dan efisien, sehingga *embedding* yang dihasilkan lebih diskriminatif terhadap identitas pembicara.

Proses ekstraksi dimulai dengan konversi sinyal audio ke domain waktu-frekuensi menggunakan *Short-Time Fourier Transform* (STFT), kemudian diproyeksikan ke skala Mel melalui *Mel filter banks*. Energi pada setiap filter kemudian diubah menjadi bentuk logaritmik (*log-Mel filter bank energies*) untuk menyesuaikan dengan persepsi pendengaran manusia, serupa dengan tahap *input log-Mel spectrogram* pada Whisper (Desplanques et al., 2020; Snyder et al., 2018). Representasi log-Mel ini kemudian menjadi masukan bagi ECAPA-TDNN untuk ekstraksi *embedding*.

ECAPA-TDNN memiliki beberapa inovasi utama dibanding TDNN konvensional:

1. Res2Net-based *convolutional* blocks: Blok ini membagi fitur masukan menjadi beberapa subset kanal dan memprosesnya secara bertahap, memungkinkan model menangkap karakteristik pembicara pada konteks temporal pendek dan panjang secara simultan.
2. Squeeze-and-Excitation (SE) mechanism: Mekanisme *channel-wise attention* ini menimbang ulang setiap kanal fitur berdasarkan relevansi terhadap identitas pembicara. Fitur yang lebih informatif diberi bobot lebih tinggi, meningkatkan kemampuan model membedakan pembicara dalam kondisi akustik yang bervariasi (Hu et al., 2018).
3. *Feature* propagation and aggregation: Representasi dari beberapa lapisan digabungkan untuk memperkaya *embedding* akhir, sehingga model lebih robust terhadap data terbatas atau variasi lingkungan (Desplanques et al., 2020).

Transformasi dari frame-level menjadi vektor berdimensi tetap dilakukan menggunakan *attentive statistics pooling*, yang memberi bobot lebih besar pada frame yang lebih informatif terhadap identitas pembicara. Hasil akhirnya adalah *speaker embedding* berdimensi tetap, biasanya 128-D atau 292-D, yang kemudian dinormalisasi (*L2 normalization*) agar siap digunakan untuk perbandingan jarak

atau klasifikasi menggunakan metode seperti *prototypical network*, *PLDA*, atau classifier berbasis neural network (Okabe et al., 2018).

Secara konseptual, proses ECAPA-TDNN sejalan dengan prinsip *Whisper encoder*: keduanya memproses *log-Mel spectrogram* melalui jaringan lapis dalam untuk menghasilkan representasi audio berdimensi tinggi yang robust terhadap variasi bahasa, aksen, dan kondisi lingkungan. Bedanya, ECAPA-TDNN dioptimalkan khusus untuk identifikasi pembicara, sedangkan *Whisper encoder* dioptimalkan untuk transkripsi suara multibahasa, namun representasi internal *Whisper* dapat digunakan sebagai *speaker embedding*, sehingga keduanya dapat dikombinasikan untuk meningkatkan performa sistem identifikasi pembicara dalam skenario dunia nyata.

### 3.5 Embedding Fusion

*Embedding fusion* adalah teknik dalam pembelajaran mesin yang bertujuan untuk menggabungkan beberapa representasi vektor fitur (*embeddings*) yang diekstraksi dari model atau sumber yang berbeda menjadi satu representasi akhir yang lebih informatif dan kuat (*robust*). Teknik ini sangat relevan dalam sistem identifikasi pembicara modern yang menggunakan multi-*backbone* architectures, di mana masing-masing model menangkap aspek karakteristik suara yang berbeda seperti dinamika temporal, konteks akustik multibahasa, atau pola fonetik khas pembicara (Li et al., 2021).

Dalam konteks sistem identifikasi pembicara, *embedding fusion* membantu mengintegrasikan informasi komplementer dari berbagai model. Contohnya, model seperti ECAPA-TDNN unggul dalam menangkap dinamika temporal lokal dan fitur diskriminatif speaker-specific, sedangkan model berbasis *pre-trained ASR* seperti *Whisper encoder* unggul dalam menangkap representasi akustik yang kuat terhadap variasi bahasa, noise, dan kondisi perekaman global. Dengan melakukan fusion pada *embedding* yang dihasilkan, sistem dapat memperoleh representasi speaker yang lebih lengkap dibandingkan dengan menggunakan satu sumber *embedding* saja.

Secara umum, metode *embedding* fusion dapat dibagi menjadi beberapa pendekatan utama berdasarkan bagaimana representasi vektor digabungkan:

1. *Concatenation* merupakan metode dasar di mana vektor *embedding* dari masing-masing model disusun secara berurutan untuk membentuk satu vektor gabungan. Cara ini sederhana namun efektif di banyak aplikasi karena mempertahankan seluruh informasi dari setiap model sebelum tahap pemrosesan selanjutnya.
2. *Weighted sum* or *weighted concatenation* yang memberikan bobot pada setiap *embedding* berdasarkan relevansi atau kontribusinya terhadap representasi akhir. Bobot ini dapat ditetapkan secara manual atau dipelajari secara otomatis selama *training*, memungkinkan model menekankan *embedding* yang lebih informatif sementara meredam kontribusi yang kurang relevan.
3. *Attention-based* fusion memanfaatkan mekanisme *attention* untuk menentukan berat relatif dari masing-masing *embedding* berdasarkan konteks *input*. Pendekatan ini semakin populer karena dapat secara adaptif mempelajari bobot kontribusi fitur dari setiap sumber *embedding*, sehingga representasi akhir menjadi lebih sensitif terhadap variasi *input* dan komponen yang benar-benar relevan dengan identitas pembicara. *Attention-based* fusion juga memungkinkan hubungan non-linear antar *embedding* untuk dimodelkan lebih efektif dibandingkan metode linear sederhana.

Pendekatan fusion yang lebih kompleks juga telah dikembangkan dalam literatur speaker recognition, di mana beberapa strategi *multi-scale fusion* dan *co-attention mechanisms* telah ditunjukkan mampu meningkatkan performa sistem ketika fitur dari domain berbeda digabungkan secara dinamis berdasarkan konteks sinyal (Li et al., 2025).

*Embedding* fusion tidak hanya meningkatkan *robustness* dan kemampuan diskriminatif dari representasi speaker, tetapi juga membantu menangani kasus di mana satu sumber *embedding* mungkin tidak memberikan informasi yang cukup lengkap. Representasi akhir yang dihasilkan melalui *fusion* biasanya digunakan

dalam tahapan selanjutnya seperti perbandingan jarak atau sebagai masukan bagi model klasifikasi lanjutan seperti *prototypical networks* atau *PLDA* untuk membuat keputusan identitas pembicara yang lebih akurat. Di antara ketiga pendekatan tersebut, penelitian ini menetapkan penggunaan *attention-based fusion* sebagai metode *fusion* yang diterapkan pada sistem yang diusulkan, dengan mekanisme dan pertimbangan desain dijelaskan secara rinci pada Bab IV.

### 3.6 Klasifikasi Few-Shot Learning

Few-shot learning (FSL) merupakan salah satu paradigma pembelajaran mesin yang bertujuan untuk memungkinkan model melakukan klasifikasi terhadap kelas baru dengan jumlah data latih yang sangat terbatas. Berbeda dengan pendekatan pembelajaran terawasi konvensional yang memerlukan data berlabel dalam jumlah besar, few-shot learning dirancang untuk meniru kemampuan manusia dalam mengenali konsep atau objek baru hanya berdasarkan beberapa contoh. Pendekatan ini menjadi sangat relevan pada berbagai aplikasi dunia nyata, termasuk pengenalan pembicara, citra medis, dan sistem biometrik, di mana ketersediaan data berlabel sering kali terbatas dan mahal untuk dikumpulkan (Wang et al., 2020).

Secara umum, permasalahan few-shot learning diformulasikan dalam skema N-way K-shot classification, di mana model dihadapkan pada tugas untuk membedakan N kelas dengan hanya K contoh untuk setiap kelas yang tersedia pada support set. Selanjutnya, performa model dievaluasi menggunakan query set yang berisi sampel berbeda namun berasal dari kelas yang sama. Skema ini bertujuan untuk mengukur kemampuan model dalam melakukan generalisasi terhadap kelas baru yang tidak pernah muncul pada proses pelatihan konvensional, tetapi memiliki karakteristik serupa dengan kelas yang telah dipelajari sebelumnya.

Pendekatan few-shot learning modern umumnya mengadopsi konsep meta-learning atau metric-based learning. Pada pendekatan berbasis metrik, model tidak secara langsung mempelajari fungsi klasifikasi parametrik, melainkan mempelajari fungsi *embedding* yang memetakan data *input* ke dalam ruang fitur

berdimensi tetap. Dalam ruang ini, sampel dari kelas yang sama diharapkan memiliki jarak yang lebih dekat dibandingkan dengan sampel dari kelas yang berbeda. Salah satu metode yang paling banyak digunakan dalam pendekatan ini adalah Prototypical Network, yang diperkenalkan oleh Snell et al. (2017), karena kesederhanaan arsitektur dan kemampuannya dalam menangani penambahan kelas baru secara efisien.

Pada Prototypical Network, setiap kelas direpresentasikan oleh sebuah vektor prototipe yang diperoleh dari rata-rata *embedding* seluruh sampel pada kelas tersebut di support set. Secara matematis, jika  $S_k$  menyatakan himpunan sampel support untuk kelas ke- $k$  dan  $f_\phi(\cdot)$  adalah fungsi *embedding* dengan parameter  $\phi$ , maka prototipe kelas  $c_k$  didefinisikan sebagai:

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_\phi(x_i) \quad (3.6)$$

Rumus ini memastikan bahwa prototipe berfungsi sebagai pusat representasi kelas dalam ruang *embedding*. Untuk proses klasifikasi, *embedding* dari sampel uji (query) dibandingkan dengan seluruh prototipe kelas menggunakan matrik jarak, seperti Euclidean distance atau cosine similarity. Probabilitas suatu sampel query diklasifikasikan ke dalam kelas tertentu dihitung menggunakan fungsi *softmax* berbasis jarak, sehingga kelas dengan jarak terdekat terhadap *embedding* query dipilih sebagai hasil prediksi.

Proses pelatihan pada few-shot learning umumnya dilakukan menggunakan pendekatan episodic *training*, di mana model dilatih melalui serangkaian *episode* yang masing-masing menyerupai skenario N-way K-shot. Pendekatan ini bertujuan untuk menyelaraskan kondisi pelatihan dengan kondisi pengujian, sehingga model terbiasa melakukan adaptasi cepat terhadap kelas baru dengan data terbatas. Fungsi kerugian yang digunakan pada proses ini biasanya berupa negative log-likelihood loss, yang mendorong *embedding* sampel uji untuk mendekati prototipe kelas yang benar dan menjauhi prototipe kelas lainnya.

Dengan karakteristik tersebut, klasifikasi few-shot learning sangat sesuai untuk diterapkan pada sistem identifikasi pembicara. Dalam konteks ini, model

diharapkan mampu mengenali pembicara baru hanya berdasarkan beberapa contoh suara, tanpa perlu dilakukan pelatihan ulang secara menyeluruh. Pendekatan ini tidak hanya meningkatkan efisiensi penggunaan data, tetapi juga memungkinkan sistem bersifat adaptif dan scalable dalam menghadapi penambahan pembicara baru.

### 3.7 Prototypical Network

Prototypical Network merupakan salah satu metode metric-based few-shot learning yang diperkenalkan oleh Snell, Swersky, dan Zemel (2017) dengan tujuan untuk melakukan klasifikasi pada kondisi jumlah data latih yang sangat terbatas. Metode ini berangkat dari asumsi bahwa setiap kelas dalam ruang *embedding* dapat direpresentasikan oleh sebuah vektor pusat (prototype), dan bahwa proses klasifikasi dapat dilakukan dengan membandingkan jarak antara sampel uji terhadap prototipe masing-masing kelas. Pendekatan ini tidak memerlukan classifier parametrik tambahan, sehingga sangat efisien dan fleksibel untuk menangani penambahan kelas baru.

Secara konseptual, Prototypical Network mempelajari sebuah fungsi *embedding* nonlinier yang memetakan data *input* ke dalam ruang vektor berdimensi tetap, di mana jarak antar vektor mencerminkan tingkat kemiripan semantik atau identitas kelas. Dalam konteks few-shot learning, model dilatih menggunakan skema episodic *training* yang menyerupai kondisi pengujian sesungguhnya, yaitu klasifikasi N-way K-shot. Setiap *episode* terdiri dari support set yang digunakan untuk membentuk prototipe kelas dan query set yang digunakan untuk mengevaluasi performa klasifikasi (Snell et al., 2017).

Secara matematis, misalkan  $S_k$  adalah himpunan data support untuk kelas ke- $k$  dengan jumlah sampel  $|S_k|$ , dan  $f_\phi(\cdot)$  adalah fungsi *embedding* dengan parameter  $\phi$ . Prototipe kelas  $c_k$  didefinisikan sebagai rata-rata *embedding* dari seluruh sampel pada kelas tersebut, yaitu:

$$c_k = \frac{1}{|S_k|} \sum_{(x_i, y_i) \in S_k} f_\phi(x_i) \quad (3.7)$$

Rumus ini memastikan bahwa prototipe menjadi representasi pusat distribusi kelas dalam ruang *embedding*. Proses klasifikasi terhadap sampel uji (query) dilakukan dengan menghitung jarak antara *embedding* query  $Z_q = f_\phi(x_q)$  dan setiap prototipe kelas. Matrik jarak yang umum digunakan adalah *Euclidean distance* atau *cosine similarity*. Untuk metrik Euclidean, jarak didefinisikan sebagai:

$$d(z_q, c_k) = ||z_q - c_k||_2 \quad (3.8)$$

Probabilitas suatu sampel query diklasifikasikan ke dalam kelas tertentu kemudian dihitung menggunakan fungsi *softmax* berbasis jarak, sebagai berikut:

$$p(y = k|x_q) = \frac{\exp(-d(z_q, c_k))}{\sum_k \exp(-d(z_q, c_k))} \quad (3.9)$$

Kelas dengan probabilitas tertinggi atau jarak terdekat terhadap *embedding* query dipilih sebagai hasil prediksi. Pendekatan ini menjadikan Prototypical Network sangat cocok untuk skenario few-shot, karena penambahan kelas baru cukup dilakukan dengan menghitung prototipe dari sampel support tanpa perlu melakukan pelatihan ulang model secara menyeluruh. Proses pelatihan Prototypical Network dioptimalkan menggunakan fungsi kerugian *negative log-likelihood*, yang mendorong *embedding* sampel query untuk mendekati prototipe kelas yang benar dan menjauhi prototipe kelas lain. Fungsi kerugian tersebut dirumuskan sebagai:

$$L = -\log P(y = y_{true}|x_q) \quad (3.10)$$

Menurut Snell et al. (2017), formulasi ini memiliki hubungan erat dengan *Bregman divergence* dan terbukti efektif dalam mempelajari ruang *embedding* yang terstruktur dengan baik. Berbagai penelitian lanjutan menunjukkan bahwa Prototypical Network memiliki performa yang kompetitif pada berbagai domain, termasuk pengenalan pembicara, pengenalan wajah, dan klasifikasi citra medis,

terutama pada kondisi data terbatas (Wang et al., 2020). Dengan karakteristik tersebut, Prototypical Network menjadi salah satu pendekatan yang paling banyak digunakan dalam penelitian few-shot learning modern. Kesederhanaan arsitektur, efisiensi komputasi, serta kemampuannya dalam melakukan generalisasi cepat terhadap kelas baru menjadikan metode ini sangat relevan untuk sistem identifikasi pembicara berbasis speaker *embedding*, khususnya pada skenario one-shot atau few-shot learning.

### 3.8 Continual Learning Berbasis Prototype Update

Continual Learning (CL), yang juga dikenal sebagai Lifelong Learning atau Incremental Learning, merupakan paradigma pembelajaran mesin yang memungkinkan model untuk mempelajari informasi baru secara bertahap tanpa kehilangan pengetahuan yang telah diperoleh sebelumnya (Parisi et al., 2019; De Lange et al., 2021). Masalah utama yang dihadapi dalam continual learning adalah *catastrophic forgetting*, yaitu penurunan performa secara signifikan pada tugas atau data lama setelah model diperbarui menggunakan data baru (McCloskey & Cohen, 1989). Oleh karena itu, tujuan utama continual learning adalah mencapai keseimbangan antara *plasticity*, kemampuan mempelajari informasi baru, dan *stability*, kemampuan mempertahankan pengetahuan lama.

Dalam sistem identifikasi pembicara modern, terutama pada skenario one/few-shot learning dengan *open-set identification*, continual learning dapat diterapkan melalui prototype update berbasis *embedding*. Dalam pendekatan ini, setiap pembicara direpresentasikan sebagai *prototype* dalam ruang *embedding*, yang biasanya merupakan rata-rata *embedding* dari seluruh contoh suara pembicara tersebut. Saat sistem menerima *input* audio baru, *embedding* dari *input* tersebut dibandingkan dengan seluruh prototype yang ada. Jika jarak antara *embedding* baru dan prototype berada di bawah ambang batas tertentu, *input* diidentifikasi sebagai *known speaker*. Sebaliknya, jika jarak melebihi ambang batas, sistem menandai *input* sebagai *unknown speaker*, sehingga mendukung skenario *open-set* di mana tidak semua pembicara telah tersedia dalam basis data (Snell et al., 2017; Kishan et al., 2022). Nilai ambang batas ini ditentukan melalui

analisis kurva *Receiver Operating Characteristic* (ROC) pada titik *Equal Error Rate* (EER), dengan metodologi dan skema data kalibrasi yang dijelaskan secara rinci pada Bab IV (Kinnunen & Li, 2010). Kriteria konkret untuk memutuskan kapan sekumpulan sampel *unknown* layak dijadikan *prototype* baru, berdasarkan akumulasi sampel minimum dan validasi *Silhouette Coefficient* (Rousseeuw, 1987; Roy et al., 2022).

Untuk menjaga sistem tetap adaptif terhadap data baru, continual learning diterapkan melalui mekanisme inkremental pada *prototype*. *Embedding* baru dapat digunakan untuk memperbarui *prototype* yang ada atau menambahkan *prototype* baru bagi pembicara yang belum dikenal, tanpa perlu melakukan pelatihan ulang seluruh model. Pendekatan ini memungkinkan model memperluas pengetahuan tentang pembicara baru sekaligus memodifikasi representasi pembicara lama secara bertahap, sehingga mengurangi risiko catastrophic forgetting dan mempertahankan performa identifikasi jangka panjang (Kirkpatrick et al., 2017; Parisi et al., 2019).

Selain itu, *prototype* yang diperbarui disimpan dalam *speaker database* untuk memastikan bahwa sistem selalu menggunakan representasi terbaru saat melakukan identifikasi di masa mendatang. Dengan strategi ini, sistem dapat secara adaptif menanggapi dinamika penambahan pembicara baru dan variasi data suara, sekaligus memaksimalkan efisiensi penggunaan data terbatas. Pendekatan ini sangat relevan untuk aplikasi dunia nyata, di mana jumlah pembicara terus bertambah dan kondisi perekaman bersifat bervariasi.

Dengan kombinasi *backbone embedding* modern, *prototypical network* untuk *one-shot learning*, identifikasi *open-set*, dan continual learning berbasis *prototype update*, sistem identifikasi pembicara yang diusulkan mampu bersifat efisien, adaptif, dan robust, serta cocok untuk implementasi dalam lingkungan nyata dengan data yang bersifat inkremental dan terbatas (Snell et al., 2017; Kirkpatrick et al., 2017; Parisi et al., 2019).

### 3.9 Metrik Evaluasi Performa

Untuk mengukur performa sistem identifikasi pembicara empat metrik evaluasi yang saling melengkapi: *Accuracy* untuk mengukur ketepatan klasifikasi secara umum, *Equal Error Rate* (EER) untuk mengukur keseimbangan kesalahan pada skenario *open-set*, serta *Average Accuracy* dan *Forgetting Measure* untuk mengukur performa dan stabilitas sistem sepanjang proses *continual learning* berlangsung.

*Accuracy* didefinisikan sebagai proporsi prediksi yang benar terhadap keseluruhan sampel uji, dihitung menggunakan persamaan berikut, dengan  $N$  adalah jumlah total sampel uji,  $\hat{y}_i$  adalah label hasil prediksi,  $y_i$  adalah label sebenarnya, dan  $\mathbb{1}[\cdot]$  adalah fungsi indikator yang bernilai 1 jika argumennya benar dan 0 jika salah:

$$Acc = \frac{1}{N} \sum_{i=1}^N \mathbb{1}[\hat{y}_i = y_i] \quad (3.11)$$

*Equal Error Rate* (EER) merupakan titik pada kurva ROC di mana *False Acceptance Rate* (FAR) sama besar dengan *False Rejection Rate* (FRR), sesuai penjelasan mekanisme *threshold* pada Bab IV. Kedua metrik penyusunnya dihitung sebagai:

$$FAR(\theta) = \frac{FP}{FP + TN} \quad (3.12)$$

$$FRR(\theta) = \frac{FN}{FN + TP} \quad (3.13)$$

dengan  $FP$ ,  $TN$ ,  $FN$ , dan  $TP$  berturut-turut adalah jumlah *false positive*, *true negative*, *false negative*, dan *true positive* pada ambang batas  $\theta$  tertentu. Nilai EER adalah nilai FAR (setara FRR) pada ambang batas  $\theta^*$  di mana keduanya berpotongan (Kinnunen & Li, 2010).

*Average Accuracy* mengukur rata-rata akurasi model pada seluruh tugas (*task*) yang telah dipelajari hingga tugas ke- $T$ , mengikuti definisi baku yang diperkenalkan oleh Lopez-Paz dan Ranzato (2017):

$$A_T = \frac{1}{T} \sum_{i=1}^T a_{T,i} \quad (3.14)$$

dengan  $a_{T,i}$  adalah akurasi model pada tugas ke- $i$  setelah model dilatih hingga tugas ke- $T$ .

*Forgetting Measure* mengukur tingkat penurunan performa pada tugas-tugas lama akibat pembelajaran tugas baru, mengikuti definisi baku yang diperkenalkan oleh Chaudhry et al. (2018):

$$F_T = \frac{1}{T-1} \sum_{i=1}^{T-1} (a_{l,i} - a_{T,i}) \quad (3.15)$$


Nilai *Forgetting Measure* yang lebih rendah menunjukkan kemampuan mempertahankan pengetahuan lama yang lebih baik, sehingga metrik ini secara langsung merepresentasikan tingkat *catastrophic forgetting* yang dialami sistem sepanjang proses *continual learning*.

## BAB IV

### METODOLOGI PENELITIAN

#### 4.1 Deskripsi Penelitian

Penelitian ini merupakan studi eksperimental yang dirancang untuk mengembangkan sistem identifikasi pembicara berbasis pendekatan *one-shot learning* dengan integrasi *multi-backbone embedding*. Sistem yang diusulkan bertujuan untuk mengenali individu hanya dari sejumlah kecil sampel suara, sekaligus mampu menangani skenario *open-set identification* dan adaptasi bertahap terhadap pembicara baru, tanpa mengurangi akurasi terhadap pembicara yang telah dikenal sebelumnya. Pendekatan ini relevan untuk aplikasi dunia nyata yang menghadapi tantangan seperti variasi bahasa, kondisi akustik yang bising, perbedaan perangkat rekaman, dan variasi gaya bicara.



**Gambar 4.1** Arsitektur Sistem

Secara umum, sistem yang diusulkan memproses *input* audio melalui beberapa tahapan utama. Pada tahap awal, sinyal audio menjalani proses preprocessing berupa resampling, normalisasi amplitudo, dan reduksi noise untuk

menghasilkan sinyal yang lebih konsisten sebelum diproses lebih lanjut. Selanjutnya, digunakan *Voice Activity Detection* (VAD) berbasis Silero untuk mendeteksi segmen yang benar-benar mengandung ucapan, sehingga bagian keheningan dan kebisingan dapat dihilangkan. Segmen ucapan yang terdeteksi kemudian digabungkan melalui proses *speech segment aggregation*, menghasilkan potongan audio representatif yang lebih stabil untuk tahap ekstraksi fitur.

Tahap berikutnya adalah ekstraksi *embedding* pembicara menggunakan *backbone* model modern seperti ECAPA-TDNN atau *encoder Whisper*, yang telah terbukti mampu menghasilkan representasi speaker yang diskriminatif dan robust terhadap variasi bahasa serta kondisi akustik. Model *backbone* ini mengubah sinyal audio menjadi *embedding* vector, yaitu representasi numerik berdimensi rendah yang merepresentasikan karakteristik unik suara pembicara.


*Embedding* yang dihasilkan kemudian diproses menggunakan *prototypical network*, sebuah pendekatan *one-shot learning* yang membangun representasi rata-rata (prototype) untuk setiap pembicara berdasarkan contoh suara yang tersedia. Identifikasi dilakukan dengan menghitung jarak *embedding input* terhadap prototype setiap speaker, sehingga sistem dapat menentukan apakah suara berasal dari pembicara yang telah dikenal atau merupakan pembicara baru (*open-set scenario*).

Jika jarak *embedding* berada dalam ambang batas tertentu, pembicara diidentifikasi sebagai *known speaker*. Sebaliknya, jika jaraknya terlalu jauh dari seluruh prototype yang ada, sistem akan menandai *input* sebagai *unknown speaker*. Mekanisme ini memungkinkan sistem bekerja dalam kondisi *open-set*, di mana tidak semua pembicara telah tersedia dalam basis data. Untuk menjaga sistem tetap adaptif terhadap data baru, penelitian ini mengintegrasikan mekanisme *continual learning* berbasis *prototype update*, di mana *embedding* baru dapat digunakan untuk memperbarui prototype speaker secara bertahap tanpa perlu melakukan pelatihan ulang keseluruhan model. Dengan pendekatan ini, sistem mampu menambahkan pembicara baru maupun memperbarui representasi pembicara lama secara inkremental, sehingga mengurangi risiko *catastrophic forgetting* serta meningkatkan performa jangka panjang. Formulasi matematis

lengkap dari mekanisme pembaruan prototipe ini, berupa *running average* tertimbang mengikuti prinsip Mensink et al. (2013).

Akhirnya, prototype yang diperbarui disimpan melalui proses speaker database update, memastikan bahwa sistem selalu menggunakan representasi terbaru saat melakukan identifikasi di masa mendatang. Dengan kombinasi *backbone embedding modern*, *prototypical network* untuk *one-shot learning*, *open-set identification*, dan *continual learning*, penelitian ini diharapkan mampu menghasilkan sistem identifikasi pembicara yang efisien, adaptif, dan robust untuk penggunaan di lingkungan nyata dengan jumlah data terbatas serta kebutuhan penambahan speaker secara dinamis.

## 4.2 Tahapan Penelitian



Gambar 4.2 Alur Penelitian

Penelitian ini dilaksanakan melalui serangkaian tahapan yang disusun secara sistematis guna memastikan proses pengembangan sistem berjalan terstruktur dan menghasilkan luaran yang sesuai dengan tujuan penelitian. Setiap tahapan dirancang saling berkaitan, mulai dari kajian konseptual hingga implementasi dan evaluasi sistem, sehingga keseluruhan proses penelitian dapat dilakukan secara terarah dan terdokumentasi dengan baik. Adapun tahapan penelitian yang dilakukan dijelaskan sebagai berikut.

### 1. Studi Literatur

Tahap awal penelitian dilakukan melalui kajian literatur terhadap jurnal, buku, dan publikasi ilmiah yang relevan dengan topik identifikasi pembicara, one/few-shot learning, speaker *embedding*, serta teknik continual learning. Kajian ini bertujuan untuk memahami perkembangan metode terkini, mengidentifikasi keterbatasan penelitian sebelumnya, serta menentukan celah penelitian yang akan diangkat.

### 2. Penyusunan Proposal Penelitian

Berdasarkan hasil studi literatur, disusun proposal penelitian yang mencakup rumusan masalah, tujuan penelitian, metodologi yang digunakan, rancangan sistem, serta rencana pelaksanaan penelitian sebagai pedoman pelaksanaan penelitian secara keseluruhan.

### 3. Pengumpulan Data

Tahap ini dilakukan untuk memperoleh data suara yang digunakan dalam proses pelatihan dan pengujian sistem. Data yang diperoleh selanjutnya diseleksi dan dipersiapkan agar sesuai dengan kebutuhan pemodelan sistem identifikasi pembicara.

### 4. Analisis dan Pemodelan Sistem

Pada tahap ini dilakukan pengembangan sistem identifikasi pembicara melalui beberapa proses utama, yaitu:

- Preprocessing audio meliputi resampling, normalisasi amplitudo, dan reduksi noise untuk meningkatkan kualitas sinyal suara.
- Penerapan Voice Activity Detection (VAD) berbasis Silero untuk mendeteksi segmen ucapan dan menghilangkan bagian non-ucapan.
- Penggabungan segmen ucapan melalui proses speech segment aggregation untuk menghasilkan sinyal representatif.
- Ekstraksi *embedding* pembicara menggunakan *backbone* model seperti ECAPA-TDNN atau Whisper *encoder* guna memperoleh representasi numerik karakteristik suara.

- Penerapan *prototypical network* untuk membangun *prototype* masing-masing pembicara dan melakukan identifikasi berbasis jarak *embedding*.
- Implementasi mekanisme *open-set identification* untuk mendeteksi pembicara yang belum dikenal.
- Integrasi *continual learning* berbasis pembaruan *prototype* guna memungkinkan sistem beradaptasi terhadap pembicara baru tanpa pelatihan ulang menyeluruh.
- Pembaruan basis data pembicara sehingga sistem selalu menggunakan representasi terbaru.

#### 5. Evaluasi Sistem

Sistem yang telah dibangun kemudian diuji menggunakan matrik evaluasi yang sesuai untuk mengukur performa identifikasi pembicara, termasuk akurasi dan kemampuan sistem dalam mengenali pembicara baru maupun pembicara yang telah dikenal.

#### 6. Penyusunan Laporan Penelitian

Tahap akhir penelitian dilakukan dengan menyusun laporan tesis yang mendokumentasikan seluruh proses penelitian, hasil eksperimen, analisis performa sistem, serta kesimpulan dan saran untuk pengembangan penelitian selanjutnya.

### 4.3 Data

Data yang digunakan dalam penelitian ini bersumber dari *dataset* publik VoxCeleb, yaitu *VoxCeleb* (*VoxCeleb1*<sup>1</sup> dan *VoxCeleb2*<sup>2</sup>). Kedua data tersebut berisi rekaman suara dari wawancara video dengan variasi bahasa, aksen, dan kondisi akustik yang beragam. Dari sisi komposisi demografis, kedua *dataset* bersifat relatif seimbang secara gender: VoxCeleb1 terdiri atas 55% pembicara laki-laki dan 45% perempuan, sedangkan VoxCeleb2 terdiri atas 61% laki-laki dan 39% perempuan. Pembicara pada kedua *dataset* mencakup rentang etnisitas,

---

<sup>1</sup><https://tensorflow.google.cn/datasets/catalog/voxceleb>

<sup>2</sup><https://tensorflow.google.cn/datasets/catalog/voxceleb>

profesi, dan usia yang luas, dengan VoxCeleb2 secara khusus mencakup lebih dari 145 kebangsaan berbeda; metadata gender dan kebangsaan tiap pembicara bersumber dari Wikipedia dan disediakan resmi oleh pengembang *dataset* (Nagrani et al., 2017; Chung et al., 2018).

Secara teknis, data audio pada kedua *dataset* diekstraksi dari trek suara video YouTube, disimpan dalam format berkas *WAV* saluran tunggal (*mono-channel*) dengan frekuensi pencuplikan asli 16 kHz dan kedalaman bit 16-bit *PCM*. Kedua *dataset* bersifat terbuka dan dapat diakses secara resmi oleh peneliti di bawah lisensi *Creative Commons Attribution 4.0 International* (CC BY 4.0), dengan hak cipta konten video asli tetap berada pada pemilik aslinya. Karena bersumber dari konten publik figur publik (selebritas) yang telah dipublikasikan secara terbuka, penggunaannya untuk keperluan penelitian akademik merupakan praktik yang lazim dan diterima luas di bidang *speaker recognition*, sebagaimana ditunjukkan oleh ratusan penelitian yang telah memanfaatkan *dataset* ini sejak dipublikasikan.

**Tabel 4.1** Statistik Resmi VoxCeleb1 dan VoxCeleb2

| <b>Dataset</b>                     | <b>Jumlah Speaker</b> | <b>Jumlah Utterance</b> | <b>Total Durasi</b> |
|------------------------------------|-----------------------|-------------------------|---------------------|
| <b>VoxCeleb1</b>                   | 1.251                 | 153.516                 | ≈352 jam            |
| <b>VoxCeleb2</b>                   | 6.112                 | 1.128.246               | ≈2.442 jam          |
| <b>Gabungan (speaker-disjoint)</b> | 7.363                 | 1.281.762               | ≈2.794 jam          |

Berdasarkan statistik resmi yang dipublikasikan oleh Nagrani, Chung, dan Zisserman (2017; 2020) serta Chung, Nagrani, dan Zisserman (2018), VoxCeleb1 dan VoxCeleb2 memiliki jumlah pembicara yang bersifat *speaker-disjoint* satu sama lain (tidak ada identitas yang tumpang tindih), sehingga keduanya dapat digabungkan untuk memperbesar cakupan populasi pembicara. Rincian statistik resmi kedua *dataset* dirangkum dalam Tabel 4.1.

Kesesuaian VoxCeleb1 dan VoxCeleb2 dengan kriteria kondisi penuh gangguan yang disebutkan pada Tujuan Penelitian yaitu kebisingan latar, gema, serta variasi intonasi dan gaya bicara, didasarkan pada karakteristik resmi kedua *dataset* yang dipublikasikan langsung oleh pengembangnya. Nagrani, Chung, Xie,

dan Zisserman (2020) menyatakan secara eksplisit bahwa data VoxCeleb dikumpulkan secara “*in the wild*” dari video YouTube (wawancara, konferensi pers, pidato, dan acara publik lainnya), sehingga mengandung variasi ekstrinsik berupa *background chatter*, musik, tepuk tangan, serta *reverberation* (gema) akibat beragamnya kondisi ruangan perekaman, dan variasi intrinsik berupa *intonation* (intonasi) dan *manner of speaking* (gaya bicara) yang melekat pada masing-masing pembicara.

Dengan karakteristik tersebut, VoxCeleb1 dan VoxCeleb2 dinilai memenuhi kriteria kondisi penuh gangguan yang menjadi fokus pengujian penelitian ini, tanpa memerlukan penambahan *dataset* lain maupun augmentasi *noise* buatan, karena gangguan-gangguan tersebut sudah melekat secara alami pada proses perekaman aslinya.

Dari total 7.363 pembicara gabungan, penelitian ini menerapkan pembagian 70% untuk Data Latih Awal ( $\approx 5.154$  pembicara) dan 30% untuk Data Uji Global ( $\approx 2.209$  pembicara). Dari Data Uji Global tersebut, 10% dialokasikan sebagai data simpanan ( $\approx 221$  pembicara) yang berfungsi sebagai pool pembicara *unknown* tambahan untuk pengujian *open-set*, sehingga tersisa  $\approx 1.988$  pembicara untuk dialokasikan ke skema Level Task/Episodic Split.

Skema pengujian dirancang mengikuti protokol *Few-Shot Class-Incremental Learning* (FSCIL) yang diperkenalkan oleh Tao et al. (2020) dan telah menjadi standar konsensus di bidang ini, khususnya protokol CUB200 yang menggunakan *10 sesi inkremental*, masing-masing *10-way*, *5-shot*. Penelitian ini mengadaptasi protokol tersebut menjadi *10 sesi inkremental*  $\times$  *10-way*, dengan  $K=1$  (*one-shot*), sehingga total pembicara baru yang dibutuhkan adalah  $10 \times 10 = 100$  pembicara hanya sekitar 4,5% dari 2.209 pembicara yang tersedia pada Data Uji Global, jauh di bawah kapasitas yang ada.

Dari sisi kecukupan sampel per pembicara, rata-rata jumlah *utterance* per pembicara pada VoxCeleb1 dan VoxCeleb2 masing-masing adalah  $\approx 123$  dan  $\approx 185$  (dihitung dari total *utterance* dibagi total *speaker* pada Tabel 4.1), jauh melebihi kebutuhan minimal skema *one-shot* ( $K=1$  sampel *support* + beberapa sampel *query* per *episode*). Dengan demikian, baik dari sisi jumlah pembicara maupun

jumlah sampel per pembicara, *dataset* VoxCeleb1 dan VoxCeleb2 dinilai *lebih dari cukup* untuk mendukung seluruh skenario *one-shot learning*, *open-set identification*, dan *continual learning* inkremental yang direncanakan dalam penelitian ini.

Seluruh data dibagi berdasarkan prinsip speaker disjoint split, yaitu setiap pembicara hanya muncul pada satu bagian pembagian data sehingga tidak terjadi tumpang tindih antara data latih dan data uji. Proses pembagian dilakukan pada dua level, yaitu:

1. Level Global (Base Split)

- a. Data Latih Awal (70% dari total pembicara) digunakan pada tahap *base training* untuk mengenali pembicara awal.
- b. Data Uji Global (30% dari total pembicara) digunakan untuk evaluasi akhir, mencakup seluruh pembicara dari berbagai tahap (tasks) setelah proses continual learning.

2. Level Task / Episodic Split

Pada level ini, data diorganisasikan dalam rangkaian tugas (tasks) yang disusun secara inkremental, di mana setiap tugas memperkenalkan pembicara baru yang belum pernah dipelajari sebelumnya. Untuk setiap tugas, data dibagi menjadi:

- a. Support set, sejumlah kecil contoh suara setiap pembicara (1-5 sampel) yang digunakan sebagai data adaptasi.
- b. Query set, uji yang mencakup pembicara baru maupun pembicara lama, dipisahkan secara acak namun terkontrol untuk mencegah kebocoran data.

Evaluasi dilakukan secara *N-way K-shot episodic testing*, di mana pada setiap *episode* model diadaptasi dengan support set lalu diuji pada query set yang berisi seluruh pembicara yang telah dikenali hingga tahap tersebut. Setelah setiap penambahan pembicara baru, model diuji kembali pada gabungan pembicara lama dan baru untuk mengukur akurasi terkini serta tingkat forgetting.

#### 4.4 Preprocessing Data

Tahap ini bertujuan untuk menyiapkan data audio agar layak digunakan pada proses ekstraksi fitur dengan memastikan kualitas sinyal yang konsisten. Proses yang dilakukan meliputi:

1. *Voice Activity Detection (VAD)*

Menggunakan model *Silero VAD* untuk mendeteksi segmen ucapan dalam rekaman audio dan mengabaikan bagian yang hanya mengandung kebisingan atau keheningan. Langkah ini memastikan hanya bagian relevan dari audio yang diproses lebih lanjut.

2. *Penghapusan Keheningan (Silence Removal)*

Menggabungkan seluruh segmen yang teridentifikasi sebagai ucapan menjadi satu berkas audio bersih, sehingga durasi audio lebih efisien dan bebas dari jeda tidak perlu.

3. *Normalisasi Volume*

Menstandarkan tingkat loudness audio pada target  $-20$  dB LUFS untuk mengurangi perbedaan volume antar rekaman, sehingga model tidak terpengaruh oleh variasi intensitas suara.

4. *Standardisasi Durasi Audio (Padding)*

Audio hasil normalisasi volume distandarkan durasinya menggunakan strategi *padding* tanpa pemotongan (*truncation*), agar tidak menghilangkan informasi suara yang berpotensi diskriminatif terhadap identitas pembicara. Pertimbangan penting mengingat keterbatasan jumlah sampel pada skenario *one-shot learning*. Pada tahap pelatihan model ECAPA-TDNN, audio yang berdurasi lebih pendek dari 3 detik di-*padding* (diulang secara sirkular) hingga mencapai panjang target, mengikuti praktik pelatihan berbasis potongan berdurasi tetap yang umum digunakan pada arsitektur ini (Desplanques et al., 2020). Untuk *backbone* Whisper, audio distandarkan ke durasi tetap 30 detik dengan *padding* berupa *silence* pada audio yang lebih pendek, mengikuti spesifikasi arsitektur aslinya (Radford et al., 2022). Pada tahap pengujian dan *enrollment*, durasi penuh (*full-length*) audio tetap digunakan tanpa pemotongan, memanfaatkan

kemampuan *attentive statistics pooling* pada ECAPA-TDNN yang secara *native* menangani *input* berdurasi variabel; untuk audio yang berdurasi sangat panjang, diterapkan strategi *sliding window* dengan agregasi rata-rata *embedding* antar-*window* guna menjaga efisiensi komputasi tanpa membuang informasi suara.

Hasil dari tahap ini adalah waveform audio bersih, konsisten, dan berdurasi seragam yang siap digunakan pada tahap ekstraksi fitur.

#### 4.5 Ekstraksi Fitur (*Speaker Embedding Extraction*)

Tahap ekstraksi fitur bertujuan untuk mengubah sinyal audio hasil *preprocessing* dan segmentasi ucapan menjadi representasi numerik yang mampu merepresentasikan karakteristik unik pembicara. Pada arsitektur sistem yang diusulkan, proses ini tidak hanya menghasilkan fitur spektral, tetapi juga melibatkan ekstraksi *embedding* menggunakan beberapa *backbone model* modern yang kemudian digabungkan untuk memperoleh representasi pembicara yang lebih robust terhadap variasi kondisi akustik dan bahasa.

Secara umum, proses ekstraksi fitur dan pembentukan *embedding* dilakukan melalui beberapa tahapan. Tahap pertama adalah transformasi sinyal ke representasi spektral. Sinyal audio hasil segmentasi terlebih dahulu dikonversi menjadi representasi spektral menggunakan *Log-Mel Spectrogram*, yang merepresentasikan energi frekuensi suara pada skala mel sehingga lebih sesuai dengan karakteristik persepsi pendengaran manusia. Representasi ini menjadi masukan utama bagi model ekstraksi *embedding*.

Parameter yang digunakan dalam proses ekstraksi *Log-Mel Spectrogram* pada penelitian ini dirangkum dalam Tabel 4.2.

**Tabel 4.2** Parameter Ekstraksi Log-Mel Spectrogram

| Parameter                                              | Nilai                     |
|--------------------------------------------------------|---------------------------|
| <b>Frekuensi pencuplikan</b><br>( <i>sample rate</i> ) | 16 kHz                    |
| <b>Jumlah filter Mel</b>                               | 80 buah                   |
| <b>Ukuran jendela</b><br>( <i>window size</i> )        | 25 milidetik (400 sampel) |
| <b><i>Hop length</i></b>                               | 10 milidetik (160 sampel) |

|                                                |                                                          |
|------------------------------------------------|----------------------------------------------------------|
| <b>Fungsi jendela (<i>window function</i>)</b> | <i>Hamming</i><br>(ECAPA-TDNN), <i>Hann</i><br>(Whisper) |
|------------------------------------------------|----------------------------------------------------------|

Konfigurasi tersebut mengikuti standar yang digunakan pada penelitian ECAPA-TDNN (Desplanques et al., 2020) dan Whisper (Radford et al., 2022), yang kebetulan memiliki parameter *sample rate*, jumlah filter Mel, *window size*, dan *hop length* yang identik. Kesamaan ini memungkinkan kedua *backbone* memanfaatkan representasi *Log-Mel Spectrogram* yang konsisten sebagai masukan awal, sebelum diproses lebih lanjut oleh masing-masing arsitektur untuk menghasilkan *speaker embedding*.

Tahap kedua adalah ekstraksi embedding menggunakan multi-backbone model. Representasi spektral selanjutnya diproses melalui beberapa model *backbone* untuk menghasilkan *speaker embedding*. Pada penelitian ini digunakan model ECAPA-TDNN yang mampu menangkap karakteristik temporal suara melalui mekanisme *channel attention*, *feature aggregation*, dan *pooling* berbasis *attention* sehingga menghasilkan representasi pembicara yang diskriminatif. Selain itu, digunakan pula *encoder* berbasis *Whisper* yang memiliki kemampuan representasi audio yang kuat terhadap variasi bahasa dan kondisi lingkungan. Masing-masing *backbone* menghasilkan *embedding* yang merepresentasikan karakteristik pembicara dari perspektif representasi yang berbeda.

Tahap ketiga adalah penggabungan *embedding* (*embedding fusion*). *Embedding* yang dihasilkan dari masing-masing *backbone* terlebih dahulu diproyeksikan ke dimensi bersama menggunakan lapisan proyeksi linear (*fully-connected layer*) yang terpisah untuk setiap *backbone*, mengingat dimensi *embedding* ECAPA-TDNN (192 dimensi) berbeda dari dimensi *embedding* Whisper (512-1280 dimensi tergantung ukuran model) (Li et al., 2021). Proses *fusion* dilakukan pada level *utterance* (*utterance-level fusion*), yaitu setelah masing-masing *backbone* menghasilkan satu vektor *embedding* berdimensi tetap per sampel suara, bukan pada level *frame* (*frame-level fusion*). Pendekatan ini dipilih karena ECAPA-TDNN dan Whisper memiliki laju bingkai (*frame rate*) yang berbeda, sehingga *fusion* pada level *frame* akan memerlukan penyelarasan

temporal tambahan yang kompleks. *Embedding* ECAPA-TDNN diperoleh langsung melalui *attentive statistics pooling* bawaan arsitekturnya, sedangkan *embedding* Whisper diperoleh dengan menerapkan lapisan *pooling* serupa terhadap keluaran *encoder*-nya, mengikuti pendekatan yang digunakan pada Whisper-PMFA (Zhao et al., 2024).

Secara matematis, proses *embedding fusion* pada penelitian ini diformulasikan melalui tiga tahap berikut. Pertama, setiap *embedding backbone*  $e_i$  (untuk  $i \in \{\text{ECAPA-TDNN}, \text{Whisper}\}$ ) diproyeksikan ke dimensi bersama menggunakan lapisan linear dengan bobot  $W_i$  dan bias  $b_i$ :

$$e'_i = W_i e_i + b_i \quad (4.1)$$

Kedua, nilai *gate*  $g$  dihitung dari gabungan (*concatenation*) kedua *embedding* terproyeksi melalui fungsi sigmoid  $\sigma$ , dengan bobot  $W_g$  dan bias  $b_g$  yang dipelajari selama pelatihan:

$$g = \sigma(W_g [e'_1; e'_2] + b_g) \quad (4.2)$$

Ketiga, representasi akhir  $e_{\text{fusion}}$  diperoleh melalui kombinasi berbobot elemen-demi-elemen (*element-wise*, dinotasikan  $\odot$ ) antara kedua *embedding* terproyeksi, menggunakan nilai *gate*  $g$  sebagai bobot adaptif:

$$e_{\text{fusion}} = g \odot e'_1 + (1 - g) \odot e'_2 \quad (4.3)$$

Dimensi akhir  $e_{\text{fusion}}$  mengikuti dimensi ruang proyeksi bersama yang ditetapkan (256 dimensi pada penelitian ini), sehingga representasi ini memiliki ukuran yang konsisten terlepas dari perbedaan dimensi asli kedua *backbone*, dan siap digunakan sebagai masukan bagi *prototypical network* pada tahap identifikasi pembicara.

Mekanisme ini bersifat *trainable* (dilatih bersama seluruh jaringan secara *end-to-end*), bukan bobot statis. Pemilihan bobot yang dilatih (bukan statis) didasarkan pada pertimbangan bahwa kontribusi relatif tiap *backbone* dapat bervariasi tergantung kondisi akustik *input*, misalnya Whisper berpotensi lebih andal pada kondisi bising sementara ECAPA-TDNN lebih andal pada kondisi bersih. Sehingga bobot tetap kurang optimal dibandingkan bobot adaptif. Mekanisme *gated attention* ini secara konseptual selaras dengan pendekatan *gated*

*fusion layer* pada Wang et al. (2025) dan *attention adaptor* pada Whisper-SV (Zhang et al., 2024), yang keduanya menerapkan prinsip pembobotan adaptif serupa dalam konteks penggabungan representasi berbasis Whisper. Representasi akhir hasil *gated attention fusion* inilah yang selanjutnya digunakan sebagai masukan bagi *prototypical network* untuk proses identifikasi pembicara.

Tahap akhir adalah normalisasi dan pembentukan representasi akhir. *Embedding* hasil penggabungan kemudian dinormalisasi untuk memastikan konsistensi skala representasi sebelum digunakan pada tahap identifikasi berbasis *prototypical network*. Representasi akhir ini berupa vektor berdimensi tetap yang siap digunakan untuk proses perbandingan jarak antar pembicara.

Dengan pendekatan *multi-backbone embedding* dan proses *fusion*, tahap ekstraksi fitur diharapkan mampu menghasilkan representasi pembicara yang lebih robust terhadap variasi kondisi rekaman, bahasa, dan lingkungan, sehingga meningkatkan performa sistem identifikasi pembicara pada skenario dunia nyata.

#### 4.6 Prototypical Network untuk Identifikasi Pembicara

*Embedding* pembicara yang dihasilkan pada tahap ekstraksi fitur selanjutnya diproses menggunakan *Prototypical Network*, yaitu metode klasifikasi berbasis jarak yang dirancang untuk skenario *one-shot* atau *few-shot learning*. Pendekatan ini memungkinkan sistem mengenali pembicara hanya dengan sedikit contoh suara melalui pembentukan representasi pusat kelas (*prototype*) di ruang *embedding*, tanpa memerlukan pelatihan ulang model setiap kali kelas baru ditambahkan.

Tahap ini meliputi beberapa proses

1. Pembentukan *Episode* Pelatihan (*Episodic Sampling*)

Data pelatihan disusun dalam bentuk *episode N-way K-shot*, yang terdiri atas sejumlah kelas pembicara dengan beberapa contoh suara pada setiap kelas. Data dibagi menjadi support set untuk membangun *prototype* dan *query set* untuk mengevaluasi proses identifikasi, sehingga model terbiasa bekerja pada kondisi dengan jumlah data terbatas.

2. Pembentukan *Prototype* Pembicara

*Embedding* dari seluruh sampel pada support set untuk setiap pembicara dirata-ratakan guna membentuk satu vektor representasi pusat kelas (*prototype*). *Prototype* ini merepresentasikan karakteristik utama setiap pembicara di ruang *embedding*.

### 3. Proses Identifikasi Berbasis Jarak

*Embedding* suara masukan dihitung jaraknya terhadap seluruh *prototype* pembicara menggunakan metrik jarak seperti *cosine similarity* atau *Euclidean distance*, kemudian nilai jarak tersebut dikonversi menjadi probabilitas kelas melalui fungsi *softmax* terhadap jarak negatif, sehingga *prototype* dengan jarak paling kecil memperoleh probabilitas tertinggi dan dipilih sebagai hasil identifikasi. Untuk mendukung skenario open-set identification, jarak minimum yang diperoleh selanjutnya dibandingkan dengan ambang batas yang ditentukan melalui proses validasi. Apabila jarak tersebut berada di bawah ambang batas, *input* diklasifikasikan sebagai pembicara yang dikenal, sedangkan jika melebihi ambang batas, *input* dinyatakan sebagai pembicara tidak dikenal (*unknown speaker*), sehingga sistem dapat menghindari pemaksaan klasifikasi pada kelas yang tidak sesuai.

### 4. Penentuan Ambang Batas (*Threshold*) untuk Open-Set Identification

Nilai ambang batas (*threshold*) yang digunakan untuk membedakan pembicara dikenal (*known speaker*) dan pembicara tidak dikenal (*unknown speaker*) ditentukan melalui analisis kurva *Receiver Operating Characteristic* (ROC) atau *Detection Error Trade-off* (DET), mengikuti metodologi baku yang lazim digunakan dalam penelitian identifikasi dan verifikasi pembicara (Kinnunen & Li, 2010). Melalui pendekatan ini, ambang batas dipilih pada titik *Equal Error Rate* (EER), yaitu titik pada kurva di mana *False Acceptance Rate* (FAR) sama besar dengan *False Rejection Rate* (FRR). Pemilihan titik EER memberikan keseimbangan optimal antara risiko menerima pembicara yang sebenarnya tidak dikenal (*false acceptance*) dan risiko menolak pembicara yang sebenarnya telah terdaftar (*false rejection*). Pendekatan ini juga selaras dengan metrik EER

yang telah ditetapkan sebagai salah satu ukuran evaluasi utama pada penelitian ini, sehingga proses penentuan ambang batas tidak memerlukan metrik tambahan di luar kerangka evaluasi yang telah dirancang. Proses penentuan ambang batas ini dilakukan pada tahap kalibrasi tersendiri, yaitu setelah proses *base training* pada Data Latih Awal (70% populasi pembicara) selesai dilaksanakan, dan sebelum evaluasi pada skema Level Task/Episodic Split dimulai. Data yang digunakan pada tahap kalibrasi ini disusun ke dalam dua kelompok pasangan (*pairs*). Pertama, pasangan *genuine*, yaitu perbandingan antara *embedding* suatu sampel dengan *prototype* pembicara yang sama, diambil dari populasi pembicara pada Data Latih Awal. Kedua, pasangan *impostor* atau *unknown*, yaitu perbandingan antara *embedding* suatu sampel dengan *prototype* pembicara yang berbeda, diambil dari sisa populasi pembicara pada Data Uji Global yang tidak digunakan dalam sesi inkremental (di luar 100 pembicara yang dialokasikan untuk 10 sesi  $\times$  10-way) maupun dalam data simpanan sebesar 10%. Dengan skema ini, data yang telah dipakai untuk kalibrasi ambang batas tetap terpisah tegas dari data yang digunakan pada sesi pengujian inkremental maupun pada pengujian *open-set* akhir, sehingga tidak terjadi kebocoran data (*data leakage*) antar-tahap. Secara rinci, tahapan penentuan ambang batas dilaksanakan melalui langkah-langkah berikut. *Pertama*, setelah model *backbone* dan *prototypical network* selesai dilatih pada Data Latih Awal, *embedding* dihitung untuk seluruh sampel pada kedua kelompok pasangan yang telah ditentukan. *Kedua*, jarak Euclidean antara *embedding* dan *prototype* terkait dihitung untuk setiap pasangan *genuine* maupun *impostor*. *Ketiga*, nilai ambang batas divariasikan secara bertahap di sepanjang rentang jarak yang diperoleh, dan pada setiap nilai dihitung FAR dan FRR yang bersesuaian, sehingga terbentuk kurva ROC/DET secara lengkap. *Keempat*, titik EER pada kurva tersebut diidentifikasi, dan nilai jarak pada titik tersebut ditetapkan sebagai ambang batas operasional yang bersifat tetap (*fixed*). *Kelima*, ambang batas yang telah ditetapkan ini digunakan secara konsisten pada seluruh

sesi Level Task/Episodic Split untuk menentukan status *known* atau *unknown speaker* dari setiap sampel uji, tanpa dilakukan kalibrasi ulang di setiap sesi, sehingga performa *open-set identification* dapat dievaluasi secara konsisten sepanjang proses *continual learning* berlangsung.

#### 5. Optimisasi Representasi *Embedding*

Selama proses pelatihan, parameter model dioptimalkan menggunakan fungsi kerugian berbasis probabilitas, sehingga *embedding* dari pembicara yang sama menjadi semakin berdekatan, sementara *embedding* antar pembicara berbeda semakin terpisah.

Pendekatan ini memungkinkan sistem melakukan identifikasi pembicara secara fleksibel, mendukung penambahan kelas baru tanpa pelatihan ulang menyeluruh, serta tetap stabil meskipun jumlah sampel per pembicara terbatas.

### 4.7 Pembelajaran Berkelanjutan (*Continual Learning*)

Dalam penelitian ini, *continual learning* dirancang untuk menjaga kemampuan sistem mengenali pembicara lama sekaligus memungkinkan penambahan pembicara baru secara bertahap tanpa menurunkan akurasi. Pendekatan yang digunakan berbasis *prototype update*, di mana *embedding* baru dari sampel suara digunakan untuk memperbarui representasi rata-rata (*prototype*) setiap pembicara secara inkremental. Desain *continual learning* ini mencakup beberapa aspek penting.

Aspek pertama *prototype update*: *embedding* baru digabung dengan *prototype* yang sudah ada untuk memperbarui representasi speaker secara selektif, sehingga performa terhadap pembicara lama tetap terjaga dan pembicara baru dapat ditambahkan tanpa pelatihan ulang penuh. Secara matematis, mekanisme pembaruan *prototype* pada penelitian ini diformulasikan sebagai *running average* tertimbang, bukan *exponential moving average (momentum update)*. Misalkan *prototype* pembicara ke- $k$  pada tahap  $t-1$  dinotasikan sebagai  $c_k(t-1)$ , dihitung dari  $n_k(t-1)$  sampel yang telah diamati sebelumnya. Ketika  $m$  sampel baru untuk pembicara yang sama tiba, dengan rata-rata

$$\text{embedding } \bar{z}_{\text{new}} = \left(\frac{1}{m}\right) \sum f\varphi(x_{\text{new}}, i), \quad (4.4)$$

maka jumlah sampel kumulatif dan prototipe diperbarui melalui persamaan berikut.

$$n_k(t) = n_k(t-1) + m \quad (4.5)$$

$$c_k(t) = \frac{n_k(t-1) \times c_k(t-1) + m \times \bar{z}_{\text{new}}}{n_k(t)} \quad (4.6)$$

Pembaruan ini bersifat *unbiased* terhadap rata-rata sebenarnya (*true mean*) dari seluruh sampel yang pernah diamati untuk pembicara tersebut. Secara matematis setara dengan menghitung ulang rata-rata dari awal menggunakan seluruh riwayat sampel, namun *tanpa perlu menyimpan embedding mentah dari sampel-sampel sebelumnya*, cukup menyimpan pasangan  $(c_k, n_k)$  untuk setiap pembicara. Formulasi ini merupakan perluasan langsung dari definisi prototipe pada Prototypical Network (persamaan 4.5–4.6) ke ranah *continual learning*, mengikuti prinsip pembaruan rata-rata kelas inkremental yang diperkenalkan oleh Mensink et al. (2013) untuk klasifikasi berbasis *Nearest Class Mean* yang dapat mengakomodasi kelas baru secara kontinu dengan biaya komputasi mendekati nol (Snell et al., 2017; Mensink et al., 2013). Berbeda dengan *exponential moving average*, pendekatan ini tidak memerlukan hyperparameter faktor peluruhan tambahan, sehingga lebih sesuai untuk skenario *one-shot/few-shot* dengan jumlah sampel per pembicara yang diketahui dan terbatas.

Untuk pembicara yang benar-benar baru (belum memiliki prototipe sebelumnya), inisialisasi dilakukan langsung dari rata-rata *embedding support set* pertama yang diterima, mengikuti persamaan 4.4, sehingga persamaan 4.5–4.6 berlaku secara konsisten baik untuk pembaruan prototipe pembicara lama maupun inisialisasi prototipe pembicara baru.

**Integrasi *Multi-backbone Embedding*:** Sistem memanfaatkan beberapa *backbone embedding*, seperti ECAPA-TDNN dan Whisper. *Embedding* dari berbagai *backbone* digabung melalui mekanisme *fusion layer* untuk menghasilkan representasi speaker yang lebih robust terhadap variasi bahasa, kondisi akustik, dan perangkat rekaman.

*Open-set Adaptation*: Sistem mampu mendeteksi pembicara baru yang tidak ada dalam basis data. Jika jarak *embedding input* terhadap semua *prototype* melebihi ambang batas, *input* dikategorikan sebagai pembicara baru dan *prototype* baru ditambahkan secara inkremental. Untuk mencegah pembentukan *prototype* baru dari sampel tunggal yang berpotensi berupa *noise* atau anomali sesaat, sistem tidak langsung mendaftarkan pembicara baru begitu satu sampel melebihi ambang batas. Sebagai gantinya, diterapkan dua kriteria yang harus terpenuhi secara bersamaan. *Pertama*, sampel yang terdeteksi *unknown* diakumulasi terlebih dahulu ke dalam *buffer* sementara hingga terkumpul jumlah sampel minimum (mengikuti skema *one-shot/few-shot* yang telah ditetapkan), bukan diputuskan dari satu deteksi tunggal. *Kedua*, kelompok sampel dalam *buffer* divalidasi menggunakan *Silhouette Coefficient* (Rousseeuw, 1987), yang mengukur kekompakan sampel-sampel tersebut sekaligus pemisahannya terhadap seluruh *prototype* yang sudah ada.

Untuk setiap sampel  $i$  dalam kelompok kandidat, dihitung:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (4.7)$$

dengan  $a(i)$  adalah rata-rata jarak sampel  $i$  terhadap sampel lain dalam kelompok kandidat (mengukur kekompakan), dan  $b(i)$  adalah rata-rata jarak sampel  $i$  terhadap *prototype* terdekat yang sudah ada (mengukur pemisahan). Apabila rata-rata  $s(i)$  untuk seluruh kelompok kandidat mendekati +1, kelompok tersebut dinyatakan cukup kompak dan terpisah jelas dari seluruh *prototype* lama, sehingga dinyatakan layak dijadikan *prototype* baru melalui inisialisasi sesuai persamaan 3.7. Sebaliknya, apabila nilai tersebut mendekati nol atau negatif, kelompok sampel dianggap belum cukup meyakinkan sebagai identitas baru yang konsisten, dan sistem akan menunggu akumulasi sampel tambahan sebelum mengambil keputusan. Pendekatan dua kriteria ini konsisten dengan kerangka kerja *class-incremental novel class discovery* yang diperkenalkan oleh Roy et al. (2022), yang menekankan pentingnya validasi ketat sebelum sampel tak berlabel didaftarkan sebagai kelas baru dalam skema pembelajaran inkremental.

*Adaptasi Bertahap dan Stabilitas Performansi*: Dengan pendekatan *prototype update*, sistem mengurangi risiko *catastrophic forgetting*, tetap

mempertahankan performa pada speaker lama, dan mendukung penambahan speaker secara dinamis dalam skenario dunia nyata dengan data terbatas. Dengan desain ini, sistem identifikasi pembicara yang diusulkan menjadi adaptif, efisien, dan robust, mampu menangani kondisi open-set, variasi lingkungan, serta kebutuhan penambahan speaker baru secara bertahap.

#### 4.8 Evaluasi, Validasi, dan Pengujian

Peneliti melakukan evaluasi untuk mengukur akurasi pengenalan pembicara, ketahanan terhadap catastrophic forgetting, serta efisiensi proses continual learning. Evaluasi ini mengikuti skema pembagian data speaker disjoint split yang memastikan setiap pembicara hanya muncul pada satu bagian pembagian data, sehingga tidak ada tumpang tindih antara data latih dan data uji.

Tahapan evaluasi dilakukan sebagai berikut:

##### 1. Pembagian Data

###### a. Level Global (*Base Split*)

Peneliti membagi seluruh data menjadi 70% Data Latih Awal untuk proses base *training* dan 30% Data Uji Global untuk evaluasi akhir. Data Uji Global memuat seluruh pembicara dari berbagai tahap (tugas) setelah proses continual learning.

###### b. Level Tugas (*Task/Episodic Split*)

Peneliti mengorganisasikan data ke dalam rangkaian tugas (tasks) secara inkremental. Setiap tugas memperkenalkan pembicara baru yang belum pernah dilatihkan sebelumnya. Untuk setiap tugas, peneliti membagi data menjadi:

- Support Set: 1–5 sampel suara per pembicara (sesuai skenario one/few-shot) untuk proses adaptasi model.
- Query Set: data uji yang berisi pembicara lama dan baru, dipisahkan secara acak namun tetap terkontrol untuk menghindari kebocoran data.

##### 2. Protokol Pengujian

Pengujian dilakukan menggunakan skema *N-way K-shot episodic testing*, dengan konfigurasi konkret 10 sesi inkremental  $\times$  10-way,  $K=1$  (one-shot) mengadaptasi protokol standar Few-Shot Class-Incremental Learning dari Tao et al. (2020) yang menggunakan 10 sesi  $\times$  10-way pada *dataset* CUB200. Pada setiap *episode*:

- a. Model diadaptasi dengan support set.
- b. Model diuji menggunakan query set yang berisi seluruh pembicara yang telah dikenali hingga tahap tersebut.
- c. Setelah penambahan pembicara baru, peneliti langsung menguji model terhadap gabungan pembicara lama dan baru untuk mengukur akurasi terkini serta tingkat forgetting.

### 3. Pengukuran Performa

- a. *Accuracy*: persentase prediksi benar pada seluruh pembicara yang dikenali.
- b. *Equal Error Rate (EER)*: titik di mana tingkat false acceptance sama dengan false rejection.
- c. *Average Accuracy*: rata-rata akurasi dari seluruh tugas yang telah dilalui.
- d. *Forgetting Measure*: selisih antara akurasi tertinggi suatu tugas dan akurasi terakhir pada tugas tersebut setelah penambahan pembicara baru.

## 4.9 Ablation Study

Untuk mengukur kontribusi masing-masing komponen arsitektur secara terpisah dan membuktikan secara empiris bahwa setiap komponen yang diusulkan memberikan manfaat nyata terhadap performa sistem, penelitian ini merancang *ablation study* yang terbagi ke dalam dua kelompok pengujian: (1) kontribusi mekanisme *fusion* dibandingkan penggunaan *backbone* tunggal, dan (2) kontribusi mekanisme *continual learning* dibandingkan sistem statis tanpa pembaruan *prototype*.

### A. Kontribusi *Embedding Fusion* terhadap *Single Backbone*

Kelompok pengujian ini membandingkan performa sistem lengkap terhadap dua varian yang hanya menggunakan satu *backbone*, dengan seluruh komponen lain (*preprocessing*, *prototypical network*, skema evaluasi 10 sesi  $\times$  10-way) dijaga identik, sehingga perbedaan hasil murni disebabkan oleh ada-tidaknya mekanisme *fusion*.

**Tabel 4.3** Konfigurasi Ablation Study Kontribusi Embedding Fusion

| Konfigurasi             | ECAPA-TD<br>NN | Whisper | Gated<br><i>Attention</i><br>Fusion |
|-------------------------|----------------|---------|-------------------------------------|
| A1 - ECAPA-TDNN<br>saja | ✓              | ✗       | ✗                                   |
| A2 - Whisper saja       | ✗              | ✓       | ✗                                   |
| A3 - Sistem lengkap     | ✓              | ✓       | ✓                                   |

Metrik pembanding yang digunakan pada kelompok ini adalah *Accuracy* dan *Equal Error Rate* (EER), dihitung pada protokol pengujian yang identik (10 sesi inkremental  $\times$  10-way,  $K=1$ ) untuk ketiga konfigurasi, sehingga selisih performa antara A3 terhadap A1 dan A2 secara langsung merepresentasikan besarnya kontribusi mekanisme *embedding fusion*.

Desain pengujian dengan membandingkan performa terhadap *backbone* tunggal sebagai *baseline* ini mengikuti preseden metodologis yang diterapkan oleh Zhao et al. (2024) pada Whisper-PMFA, yang membuktikan kontribusi arsitekturnya dengan membandingkan langsung terhadap performa ECAPA-TDNN dan ResNet34 sebagai model tunggal pada protokol pengujian yang identik.

### B. Kontribusi Continual Learning terhadap Sistem Statis

Kelompok pengujian ini membandingkan mekanisme pembaruan *prototype* (Persamaan 4.5-4.6) terhadap kondisi sistem statis, di mana *prototype* dihitung satu kali pada tahap *base training* kemudian dibekukan (*frozen*) tanpa pembaruan lebih lanjut sepanjang sesi inkremental berlangsung.

**Tabel 4.4** Konfigurasi Ablation Study — Kontribusi Continual Learning

| Konfigurasi                | Mekanisme Prototype                 | Diperbarui Tiap Sesi | Skema Evaluasi             |
|----------------------------|-------------------------------------|----------------------|----------------------------|
| <b>B1 - Static</b>         | Dihitung sekali, dibekukan (frozen) | ✗                    | 10 sesi × 10-way (identik) |
| <b>B2 - Sistem lengkap</b> | Running average                     | ✓                    | 10 sesi × 10-way (identik) |

Metrik pembandingan yang digunakan pada kelompok ini adalah *Average Accuracy* dan *Forgetting Measure*, diukur secara berkelanjutan di sepanjang 10 sesi inkremental untuk kedua konfigurasi. Selisih *Forgetting Measure* antara B1 dan B2 secara langsung merepresentasikan besarnya kontribusi mekanisme *continual learning* dalam menjaga performa terhadap pembicara lama seiring penambahan pembicara baru.

Desain pengujian dengan membandingkan mekanisme *continual learning* terhadap kondisi statis ini mengikuti preseden metodologis yang diterapkan oleh Wang et al. (2025) pada *Continual Speech Learning*, yang membuktikan kontribusi *gated-fusion layer* miliknya dengan membandingkan terhadap *baseline fine-tuning* konvensional tanpa mekanisme adaptasi khusus, menggunakan metrik *Average Forgetting* sebagai indikator utama.

Kedua kelompok *ablation study* ini dilaksanakan menggunakan pembagian data yang identik dengan skema evaluasi utama (Bab 4.8), sehingga hasil dari setiap konfigurasi dapat dibandingkan secara adil dan memberikan bukti empiris yang jelas mengenai kontribusi masing-masing komponen terhadap performa keseluruhan sistem yang diusulkan.

#### 4.10 Baseline Comparison

Selain *ablation study* pada sub-bab sebelumnya yang mengukur kontribusi komponen internal, penelitian ini juga merancang *baseline comparison* untuk membandingkan performa sistem lengkap yang diusulkan terhadap metode-metode dari literatur, guna membuktikan daya saing sistem secara empiris. *Baseline* dipilih membentuk sebuah *capability ladder* (tangga

kemampuan), yaitu rangkaian metode pembandingan yang secara bertahap semakin mendekati kemampuan penuh sistem yang diusulkan (*one-shot learning*, *open-set identification*, dan *continual learning*), sehingga kontribusi tiap kemampuan dapat diisolasi secara jelas.

**Tabel 4.5** Baseline Comparison

| Baseline                     | Sumber                    | Kemampuan yang Diuji                                                                              |
|------------------------------|---------------------------|---------------------------------------------------------------------------------------------------|
| <b>x-vector + PLDA</b>       | Snyder et al. (2018)      | Tidak ada (fondasi historis, closed-set, statis)                                                  |
| <b>ECAPA-TDNN standar</b>    | Desplanques et al. (2020) | <i>Backbone</i> sama dengan sistem diusulkan, tanpa kerangka one-shot/open-set/continual learning |
| <b>Prototypical Network</b>  | Snell et al. (2017)       | One-shot dasar, tanpa open-set dan continual learning                                             |
| <b>openFEAT</b>              | Kishan et al. (2022)      | One-shot dan open-set, tanpa pembaruan prototipe berkelanjutan lintas sesi                        |
| <b>Sistem yang diusulkan</b> | —                         | One-shot + open-set + continual learning                                                          |

Seluruh nilai performa *baseline* pada Tabel 4.5, kecuali dinyatakan lain, diperoleh dengan menjalankan ulang (*re-run*) implementasi masing-masing metode pada protokol pengujian yang identik dengan sistem yang diusulkan (*dataset* VoxCeleb1 dan VoxCeleb2, skema 10 sesi inkremental  $\times$  10-way,  $K=1$ ), bukan mengutip nilai performa yang dilaporkan pada penelitian aslinya. Hal ini penting karena protokol pengujian pada penelitian asli tiap *baseline* berbeda-beda contoh nya Prototypical Network (Snell et al., 2017) awalnya diuji pada data citra, bukan data suara, sementara openFEAT (Kishan et al., 2022) diuji pada simulasi rumah tangga dengan skema pembagian data yang berbeda dari penelitian ini. Mengutip nilai performa secara langsung dari penelitian asli tanpa menyamakan protokol pengujian akan menghasilkan perbandingan yang tidak adil (*apples-to-oranges comparison*), sehingga seluruh *baseline* yang layak direproduksi dijalankan ulang menggunakan pembagian data, *backbone* dasar, dan metrik evaluasi (Accuracy dan Equal Error Rate) yang sama dengan sistem yang diusulkan.

Untuk metode pembandingan yang kompleksitas arsitekturnya menyulitkan reimplementasi penuh dalam cakupan sumber daya penelitian ini, khususnya openFEAT dengan arsitektur *Transformer set-to-set*-nya, diterapkan strategi

bertingkat sebagai berikut. *Pertama*, diupayakan reimplementasi mekanisme inti secara disederhanakan, misalnya menggantikan modul adaptasi berbasis *Transformer* dengan lapisan adaptasi linear yang secara konsep setara, dengan penyederhanaan yang dilakukan dinyatakan secara eksplisit. *Kedua*, apabila reimplementasi bahkan dalam bentuk sederhana tidak memungkinkan, perbandingan terhadap metode tersebut dilakukan secara kualitatif berdasarkan desain dan kemampuan yang dilaporkan pada penelitian asli, tanpa mencantumkan nilai performa kuantitatif pada Tabel 4.5. *Ketiga*, apabila kedua opsi tersebut tidak memungkinkan, keterbatasan ini dinyatakan secara eksplisit pada bagian Batasan Masalah, disertai alasan metodologis yang jelas. Dengan strategi ini, penelitian tidak akan mencampurkan nilai performa yang diperoleh dari protokol pengujian yang berbeda ke dalam tabel perbandingan kuantitatif yang sama.

Dengan pendekatan *baseline comparison* yang menggunakan protokol pengujian identik ini, posisi kontribusi penelitian dapat ditunjukkan secara adil dan meyakinkan terhadap rangkaian metode pembanding, mulai dari pendekatan paling dasar hingga metode paling mendekati kemampuan sistem yang diusulkan.

#### 4.11 Uji Signifikansi Statistik

Skema evaluasi pada penelitian ini menggunakan *episodic testing*, di mana sampel pada *support set* dan *query set* diambil secara acak pada tiap *episode*. Akibatnya, selisih performa yang teramati antar konfigurasi pada *ablation study* (Bab 4.9) maupun *baseline comparison* (Bab 4.10) berpotensi disebabkan oleh variasi pengambilan sampel acak semata, bukan oleh perbedaan kemampuan metode yang sesungguhnya. Untuk memastikan bahwa selisih performa yang dilaporkan bersifat nyata dan konsisten, bukan kebetulan dari satu kali pengujian, penelitian ini menerapkan uji signifikansi statistik terhadap seluruh perbandingan performa yang disajikan pada kedua sub-bab tersebut.

Setiap konfigurasi pada *ablation study* dan *baseline comparison* dijalankan sebanyak 10 kali pengulangan independen dengan *random seed* berbeda untuk proses pengambilan sampel *episode*, menghasilkan 10 nilai *Accuracy* dan 10 nilai

*Equal Error Rate* (EER) per konfigurasi. Hasil dilaporkan dalam bentuk rata-rata dan simpangan baku (*mean  $\pm$  standard deviation*) untuk merepresentasikan variabilitas performa antar pengulangan, sebelum dilakukan uji signifikansi terhadap selisih antar konfigurasi.

Mengingat karakteristik kedua metrik berbeda, digunakan dua metode uji yang berbeda pula. Untuk metrik *Accuracy*, yang merupakan proporsi sederhana, digunakan *paired t-test* setelah asumsi normalitas data diperiksa menggunakan *Shapiro-Wilk test*; apabila asumsi normalitas tidak terpenuhi, digunakan *Wilcoxon signed-rank test* sebagai alternatif non-parametrik. Untuk metrik EER, uji signifikansi tidak dapat dilakukan dengan uji statistik sederhana karena EER merupakan metrik gabungan dari *False Acceptance Rate* (FAR) dan *False Rejection Rate* (FRR) pada titik keseimbangan keduanya, sehingga distribusinya tidak dapat didekati secara langsung dengan uji parametrik biasa. Untuk itu, digunakan pendekatan *bootstrap resampling* guna mengestimasi interval kepercayaan 95% dari selisih EER antar konfigurasi, mengikuti metodologi yang dikembangkan oleh Bengio dan Mariéthoz (2004) khusus untuk pengujian signifikansi pada metrik berbasis kesalahan otentikasi seperti EER dan *Half Total Error Rate* (HTER). Selisih dinyatakan signifikan apabila nilai nol (tidak ada selisih) berada di luar interval kepercayaan 95% yang diperoleh.

Karena pengujian ini melibatkan banyak perbandingan berpasangan sekaligus (antara lain A3 terhadap A1 dan A2 pada Tabel 4.3; B2 terhadap B1 pada Tabel 4.4; serta sistem yang diusulkan terhadap keempat *baseline* pada Tabel 4.5), diterapkan koreksi Bonferroni terhadap ambang signifikansi untuk mengontrol inflasi galat tipe I (*Type I error*) akibat pengujian berganda. Ambang signifikansi awal ditetapkan pada  $\alpha = 0,05$ , kemudian dibagi dengan jumlah total perbandingan berpasangan yang dilakukan untuk memperoleh ambang signifikansi terkoreksi yang digunakan dalam interpretasi hasil akhir.

## BAB V

### JADWAL PENELITIAN

Berikut adalah rencana jadwal penelitian yang akan dilaksanakan, disajikan pada Tabel 5.1.

**Tabel 5.1 Jadwal Penelitian**

| No | Kegiatan                                                                          | Nov<br>2025 | Des<br>2025 | Jan<br>2026 | Feb<br>2026 | Mar<br>2026 | Apr<br>2026 | Mei<br>2026 | Jun<br>2026 | Jul<br>2026 | Agu<br>2026 | Sep<br>2026 | Okt<br>2026 | Nov<br>2026 | Des<br>2026 |
|----|-----------------------------------------------------------------------------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|-------------|
| 1. | Studi Literatur                                                                   |             |             |             |             |             |             |             |             |             |             |             |             |             |             |
| 2. | Penyusunan Proposal Penelitian                                                    |             |             |             |             |             |             |             |             |             |             |             |             |             |             |
| 3. | Pengumpulan Data                                                                  |             |             |             |             |             |             |             |             |             |             |             |             |             |             |
| 4. | Analisis dan Pemodelan Sistem                                                     |             |             |             |             |             |             |             |             |             |             |             |             |             |             |
| 5. | Evaluasi Sistem (Ablation Study, Baseline Comparison, Uji Signifikansi Statistik) |             |             |             |             |             |             |             |             |             |             |             |             |             |             |
| 6. | Penyusunan Laporan Penelitian                                                     |             |             |             |             |             |             |             |             |             |             |             |             |             |             |

## DAFTAR PUSTAKA

- Bengio, S., & Mariéthoz, J. (2004). A statistical significance test for person authentication. In *Proceedings of Odyssey 2004: The Speaker and Language Recognition Workshop* (pp. 237–244). ISCA.
- Chaudhry, A., Dokania, P. K., Ajanthan, T., & Torr, P. H. S. (2018). Riemannian walk for incremental learning: Understanding forgetting and intransigence. In *Proceedings of the European Conference on Computer Vision (ECCV)* (pp. 532–547). Springer.
- Chaubey, A., Sinha, S., & Ghose, S. (2022). Improved relation networks for end-to-end speaker verification and identification. *Proc. Interspeech 2022*, 5085–5089. <https://doi.org/10.21437/Interspeech.2022-10064>
- Chen, Z., Ai, Z., Li, X., & Xu, S. (2024). Enhancing open-set speaker identification through rapid tuning with speaker reciprocal points and negative sample. *arXiv preprint*. <https://doi.org/10.48550/arXiv.2409.15742>
- Chung, J. S., Nagrani, A., & Zisserman, A. (2018). VoxCeleb2: Deep speaker recognition. *Proc. Interspeech 2018*, 1086–1090. <https://doi.org/10.21437/Interspeech.2018-1929>
- De Lange, M., Aljundi, R., Masana, M., Parisot, S., Jia, X., Leonardis, A., Slabaugh, G., & Tuytelaars, T. (2021). A continual learning survey: Defying forgetting in classification tasks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(7), 3366–3385. <https://doi.org/10.1109/TPAMI.2021.3057446>
- Desplanques, B., Thienpondt, J., & Demuynck, K. (2020). ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in TDNN based speaker verification. In *Interspeech 2020* (pp. 3830–3834). ISCA. <https://doi.org/10.21437/Interspeech.2020-2650>
- Emon, J. I., Salek, M. A., & Alam, K. T. (2025). Whisper Speaker Identification: Leveraging pre-trained multilingual transformers for robust speaker embeddings. *arXiv preprint*. <https://doi.org/10.48550/arXiv.2503.10446>
- Fei-Fei, L., Fergus, R., & Perona, P. (2006). One-shot learning of object categories. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 28(4), 594–611. <https://doi.org/10.1109/TPAMI.2006.79>
- French, R. M. (1999). Catastrophic forgetting in connectionist networks. *Trends in Cognitive Sciences*, 3(4), 128–135. [https://doi.org/10.1016/S1364-6613\(99\)01294-2](https://doi.org/10.1016/S1364-6613(99)01294-2)

- Foggia, P., Greco, A., Roberto, A., Saggese, A., & Vento, M. (2023). Few-shot re-identification of the speaker by social robots. *Autonomous Robots*, 47(2), 181–192. <https://doi.org/10.1007/s10514-022-10073-6>
- Hu, J., Shen, L., & Sun, G. (2018). Squeeze-and-excitation networks. In 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) (pp. 7132–7141). IEEE. <https://doi.org/10.1109/CVPR.2018.00745>
- Kinnunen, T., & Li, H. (2010). An overview of text-independent speaker recognition: From features to supervectors. *Speech Communication*, 52(1), 12–40. <https://doi.org/10.1016/j.specom.2009.08.009>
- Koch, G., Zemel, R., & Salakhutdinov, R. (2015). Siamese neural networks for one-shot image recognition. ICML 2015 Deep Learning Workshop. (Makalah workshop, tidak memiliki DOI resmi; bukan bagian dari prosiding utama ICML/PMLR v37 seperti disebutkan sebelumnya). PDF: <https://www.cs.cmu.edu/~rsalakhu/papers/oneshot1.pdf>
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. A., Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., & Hadsell, R. (2017). Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13), 3521–3526. <https://doi.org/10.1073/pnas.1611835114>
- Lopez-Paz, D., & Ranzato, M. (2017). Gradient episodic memory for continual learning. *Advances in Neural Information Processing Systems*, 30, 6467–6476. <https://proceedings.neurips.cc/paper/2017/hash/f87522788a2be2d171666752f97ddebb-Abstract.html>
- Larsen, C. M., Koch, P., & Tan, Z.-H. (2022). Adversarial multi-task deep learning for noise-robust voice activity detection with low algorithmic delay. *Proc. Interspeech* 2022, 3759–3763. <https://doi.org/10.21437/Interspeech.2022-10033>
- Kishan, K. C., Tan, Z., Chen, L., Jin, M., Han, E., Stolcke, A., & Lee, C. (2022). openFEAT: Improving speaker identification by open-set few-shot embedding adaptation with transformer. *Proc. IEEE ICASSP 2022*, 7062–7066. <https://doi.org/10.1109/ICASSP43922.2022.9747613>
- Li, Y., Chen, H., Cao, W., Huang, Q., & He, Q. (2023). Few-shot speaker identification using lightweight prototypical network with feature grouping and interaction. *IEEE Transactions on Multimedia*, 25, 9241–9253. <https://doi.org/10.1109/TMM.2023.3253301>

- McCloskey, M., & Cohen, N. J. (1989). Catastrophic interference in connectionist networks: The sequential learning problem. In G. H. Bower (Ed.), *Psychology of learning and motivation* (Vol. 24, pp. 109–165). Academic Press.
- McLoughlin, I., Pham, L., Song, Y., Miao, X., Phan, H., Cai, P., Gu, Q., Nan, J., Song, H., & Soh, D. (2026). Spectrogram features for audio and speech analysis. *Applied Sciences*, 16(2), Article 572. <https://doi.org/10.3390/app16020572>
- Mensink, T., Verbeek, J., Perronnin, F., & Csurka, G. (2013). Distance-based image classification: Generalizing to new classes at near-zero cost. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 35(11), 2624–2637. <https://doi.org/10.1109/TPAMI.2013.83>
- Nagrani, A., Chung, J. S., & Zisserman, A. (2017). VoxCeleb: A large-scale speaker identification dataset. *Proc. Interspeech 2017*, 2616–2620. <https://doi.org/10.21437/Interspeech.2017-950>
- Nagrani, A., Chung, J. S., Xie, W., & Zisserman, A. (2020). VoxCeleb: Large-scale speaker verification in the wild. *Computer Speech & Language*, 60, Article 101027. <https://doi.org/10.1016/j.csl.2019.101027>
- Li, P., Hoi, L. M., Wang, Y., Yang, X., & Im, S. K. (2025). Enhancing speaker recognition with CRET model: A fusion of Conv2D, ResNet and ECAPA-TDNN. *EURASIP Journal on Audio, Speech, and Music Processing*, 2025(1), Article 9. <https://doi.org/10.1186/s13636-025-00396-4>
- Okabe, K., Koshinaka, T., & Shinoda, K. (2018). Attentive statistics pooling for deep speaker embedding. In *Interspeech 2018* (pp. 2252–2256). ISCA. <https://doi.org/10.21437/Interspeech.2018-993>
- Parisi, G. I., Kemker, R., Part, J. L., Kanan, C., & Wermter, S. (2019). Continual lifelong learning with neural networks: A review. *Neural Networks*, 113, 54–71. <https://doi.org/10.1016/j.neunet.2019.01.012>
- [SUBSTITUSI: entri asli fiktif, kemungkinan dimaksudkan untuk merujuk paper Whisper asli berikut] Radford, A., Kim, J. W., Xu, T., Brockman, G., McLeavey, C., & Sutskever, I. (2022). Robust speech recognition via large-scale weak supervision. In *Proceedings of ICML 2023* (Vol. 202, pp. 28492–28518). PMLR. <https://doi.org/10.48550/arXiv.2212.04356>
- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53–65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)

- Roy, S., Liu, M., Zhong, Z., Sebe, N., & Ricci, E. (2022). Class-incremental novel class discovery. In *Computer Vision – ECCV 2022* (Vol. 13693, pp. 317–333). Springer. [https://doi.org/10.1007/978-3-031-19827-4\\_19](https://doi.org/10.1007/978-3-031-19827-4_19)
- O'Shaughnessy, D. (1987). *Speech Communication: Human and Machine*. Addison-Wesley. ISBN 978-0201165203.
- Rolnick, D., Ahuja, A., Schwarz, J., Lillicrap, T., & Wayne, G. (2019). Experience replay for continual learning. *Advances in Neural Information Processing Systems*, 32, 348–358. <https://arxiv.org/abs/1811.11682>
- Snell, J., Swersky, K., & Zemel, R. (2017). Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems (NeurIPS 2017)* (Vol. 30, pp. 4077–4087). <https://arxiv.org/abs/1703.05175>
- Snyder, D., Garcia-Romero, D., Sell, G., Povey, D., & Khudanpur, S. (2018). X-vectors: Robust DNN embeddings for speaker recognition. In *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 5329–5333). IEEE. <https://doi.org/10.1109/ICASSP.2018.8461375>
- Tan, Z., Yang, Y., Han, E., & Stolcke, A. (2021). Improving speaker identification for shared devices by adapting embeddings to speaker subsets. *Proc. IEEE Automatic Speech Recognition and Understanding Workshop (ASRU)*, 1124–1131. <https://doi.org/10.1109/ASRU51503.2021.9687975>
- Wan, L., Wang, Q., Papir, A., & Lopez Moreno, I. (2018). Generalized end-to-end loss for speaker verification. In *2018 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)* (pp. 4879–4883). IEEE. <https://doi.org/10.1109/ICASSP.2018.8462665>
- Wang, W., Zhao, H., Yang, Y., Chang, Y., & You, H. (2023). Few-shot short utterance speaker verification using meta-learning. *PeerJ Computer Science*, 9, e1276. <https://doi.org/10.7717/peerj-cs.1276>
- Wang, Y., Yao, Q., Kwok, J. T., & Ni, L. M. (2020). Generalizing from a few examples: A survey on few-shot learning. *ACM Computing Surveys*, 53(3), 63:1–63:34. <https://doi.org/10.1145/3386252>
- Wang, G., Zhao, J., Yang, H., Qi, G., Wu, T., & Haffari, G. (2025). Continual speech learning with fused speech features. *Proc. Interspeech 2025*, 1793–1797. <https://doi.org/10.21437/Interspeech.2025-1823>
- Jung, J., Zhang, W., Shi, J., Aldeneh, Z., Higuchi, T., Gichamba, A., Theobald, B.-J., Hussen Abdelaziz, A., & Watanabe, S. (2024). ESPnet-SPK: Full pipeline speaker embedding toolkit with reproducible recipes, self-supervised

front-ends, and off-the-shelf models. Proc. Interspeech 2024, 4278–4282.  
<https://doi.org/10.21437/Interspeech.2024-1345>

Zhang, L., Jiang, N., Wang, Q., Li, Y., Lu, Q., & Xie, L. (2024). Whisper-SV: Adapting Whisper for low-data-resource speaker verification. *Speech Communication*, 163, Article 103103.  
<https://doi.org/10.1016/j.specom.2024.103103>

Zhao, Y., Wang, S., Sun, G., Chen, Z., Zhang, C., Xu, M., & Zheng, T. F. (2024). Whisper-PMFA: Partial multi-scale feature aggregation for speaker verification using Whisper models. Proc. Interspeech 2024, 2680–2684.  
<https://doi.org/10.48550/arXiv.2408.15>

# LAMPIRAN

## Rekap Poin Revisi Penguji

### A. Daftar Revisi dari Dr. Dyah Aruming Tyas, S.Si.

| No | Hal.            | Poin Revisi                                                                                                                 | Penjelasan Singkat Revisi                                                                                                                                                                                                                                                                               |
|----|-----------------|-----------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | Seluruh dokumen | Istilah asing gunakan huruf <i>italic</i>                                                                                   | Seluruh istilah berbahasa asing ( <i>embedding</i> , <i>backbone</i> , <i>one-shot learning</i> , <i>open-set</i> , <i>continual learning</i> , <i>threshold</i> , dll.) dicetak miring konsisten di seluruh bab, kecuali nama arsitektur/model (ECAPA-TDNN, Whisper) dan judul kutipan Daftar Pustaka. |
| 2  | 6               | Intisari: permasalahan/latar belakang kemudian usulan metode yang digunakan                                                 | Ditambahkan paragraf pembuka yang menjelaskan keterbatasan sistem identifikasi pembicara konvensional (butuh data besar, <i>closed-set</i> ) sebelum kalimat usulan metode, sehingga alurnya menjadi masalah → solusi → proses → hasil.                                                                 |
| 3  | 3–4             | Batasan masalah dibuat dalam bentuk poin-poin saja                                                                          | Paragraf mengalir diubah menjadi kalimat pengantar singkat diikuti 4 poin bernomor (lingkup lingkungan pengujian, batasan VAD, dataset yang dipakai, batasan skala/multibahasa).                                                                                                                        |
| 4  | 12–27           | Cek kembali nomor subbab di Bab III                                                                                         | Ditemukan seluruh subbab Bab III salah bernomor “2.x” (seharusnya “3.x”) akibat kesalahan template penomoran; diperbaiki menjadi 3.1–3.9 berurutan dan konsisten dengan nomor bab.                                                                                                                      |
| 5  | 29              | Gambar 4.1, teksnya terlalu kecil                                                                                           | Diagram arsitektur sistem dibangun ulang dengan resolusi lebih tinggi dan ukuran font jauh lebih besar, disusun alur vertikal menurun, memuat pembaruan blok Standardisasi Durasi Audio dan label <i>Gated Attention Fusion</i> .                                                                       |
| 6  | 55              | Jadwal penelitian di-update                                                                                                 | Tabel jadwal diperluas dari 9 bulan (Nov 2025–Jul 2026) menjadi 14 bulan (Nov 2025–Des 2026), ditempatkan pada satu halaman berorientasi <i>landscape</i> .                                                                                                                                             |
| 7  | 39–41           | Mekanisme <i>embedding fusion</i> ( <i>concatenation</i> maupun <i>attention-based fusion</i> ) perlu diperdetail prosesnya | Ditambahkan penjelasan rinci proses <i>Gated Attention Fusion</i> sebagai metode final: proyeksi dimensi kedua <i>backbone</i> , formulasi matematis (Persamaan 4.1–4.3), serta alasan bobot <i>trainable</i> dibanding statis.                                                                         |
| 8  | 34–36           | Apakah 2 dataset sudah memenuhi kriteria gangguan (kebisingan latar, gema, variasi intonasi dan gaya bicara)?               | Ditambahkan penjelasan yang mengonfirmasi kesesuaian VoxCeleb1/VoxCeleb2 dengan mengutip karakteristik resmi dataset (Nagrani et al., 2020) yang menyebut <i>background chatter</i> , <i>reverberation</i> , <i>intonation</i> , dan <i>manner of speaking</i> .                                        |
| 9  | 27–28           | Rumus dari metrik performa perlu dituliskan                                                                                 | Ditambahkan sub-bab baru 3.9 Metrik Evaluasi Performa berisi formulasi matematis lengkap untuk Accuracy, EER (FAR/FRR), Average Accuracy, dan Forgetting Measure, masing-masing dengan sitasi sumber baku.                                                                                              |
| 10 | 34–35           | Penjelasan terkait dataset kurang lengkap                                                                                   | Ditambahkan penjelasan komposisi demografis (rasio gender, cakupan kebangsaan) serta format teknis dan lisensi dataset (WAV 16kHz, CC BY 4.0).                                                                                                                                                          |

### B. Daftar Revisi dari Prof. Drs. Edi Winarko, M.Sc., Ph.D.

| No | Hal.    | Poin Revisi                                                                                            | Penjelasan Singkat Revisi                                                                                                                                                                                                    |
|----|---------|--------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | 6–7, 12 | Cari referensi tambahan terkait identifikasi pembicara                                                 | Ditambahkan pembahasan Foggia et al. (2023), Tan et al. (2021), dan Kishan et al. (2022) mengenai identifikasi pembicara skenario <i>shared-device</i> /rumah tangga di Bab II, beserta 3 baris tambahan pada Tabel 2.1.     |
| 2  | 29, 45  | Gambar 4.1 perlu diperbesar; WavLM disebut di 4.7 tapi tidak muncul di diagram                         | Diagram dibangun ulang dengan ukuran lebih besar dan jelas; ketidaksesuaian WavLM diselesaikan dengan menyeragamkan sistem hanya menggunakan 2 <i>backbone</i> (ECAPA-TDNN dan Whisper) baik di teks 4.7 maupun diagram.     |
| 3  | 33–36   | Pemilihan dataset butuh justifikasi kuantitatif (total pembicara, jam audio, kecukupan untuk one-shot) | Dataset dipersempit ke VoxCeleb1+VoxCeleb2; ditambahkan Tabel 4.1 (statistik resmi: 7.363 pembicara, ≈2.794 jam gabungan), perhitungan <i>split</i> 70/30/10%, serta skema 10 sesi × 10-way yang membuktikan kecukupan data. |
| 4  | —       | AISHELL-4 adalah dataset <i>speech separation</i> , bukan <i>speaker identification</i>                | Dataset AISHELL-4 dihapus total dari penelitian (bersamaan dengan penyempitan ke VoxCeleb saja); tidak ada lagi kemunculan di dokumen.                                                                                       |
| 5  | 15, 36  | Parameter Log-Mel Spectrogram tidak disebutkan                                                         | Ditambahkan paragraf penjelasan di Bab III serta Tabel 4.2 di Bab IV yang mencantumkan seluruh parameter: 16 kHz, 80 filter Mel, <i>window size</i> 25ms, <i>hop length</i> 10ms.                                            |

| No | Hal.         | Poin Revisi                                                                                                                  | Penjelasan Singkat Revisi                                                                                                                                                                                                       |
|----|--------------|------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 6  | 38           | Penanganan audio berbagai panjang ( <i>padding/truncation/sliding window</i> ) tidak dijelaskan                              | Ditambahkan poin ke-4 di sub-bab Preprocessing Data yang menjelaskan strategi <i>padding</i> (bukan <i>truncation</i> ): 3 detik pelatihan ECAPA-TDNN, 30 detik Whisper, dan <i>full-length/sliding window</i> untuk inferensi. |
| 7  | 26, 42–44    | Metode penentuan <i>threshold open-set</i> tidak konkret                                                                     | Ditambahkan metodologi lengkap berbasis kurva ROC/EER, termasuk skema data kalibrasi (pasangan <i>genuine/impostor</i> ) dan 5 langkah konkret penentuan ambang batas.                                                          |
| 8  | 19, 39–41    | Sebaiknya dicoba <i>fusion</i> berbasis <i>attention</i> (perhatikan dimensi, posisi <i>pipeline</i> , bobot statis/dilatih) | Sistem menetapkan <i>Gated Attention Fusion</i> sebagai metode final, dengan formulasi matematis proyeksi dimensi, posisi <i>utterance-level fusion</i> , dan bobot <i>trainable</i> beserta alasannya.                         |
| 9  | 25–26, 45–46 | Mekanisme pembaruan prototipe tidak diformulasikan matematis                                                                 | Ditambahkan formulasi <i>running average</i> tertimbang (Persamaan 4.4–4.6) sebagai kontribusi inti penelitian, dengan penjelasan eksplisit mengapa dipilih dibanding <i>momentum update/exponential moving average</i> .       |
| 10 | 26, 46–47    | Kriteria kapan <i>unknown speaker</i> layak jadi <i>prototype</i> baru tidak ada                                             | Ditambahkan 2 kriteria: akumulasi sampel minimum di <i>buffer</i> dan validasi <i>Silhouette Coefficient</i> (Persamaan 4.7), sehingga keputusan tidak diambil dari satu sampel tunggal.                                        |
| 11 | 49–51        | Tidak ada rencana <i>ablation study</i>                                                                                      | Ditambahkan sub-bab 4.9 Ablation Study dengan 2 kelompok pengujian: kontribusi <i>fusion vs single backbone</i> (Tabel 4.3) dan <i>continual learning</i> vs sistem statis (Tabel 4.4).                                         |
| 12 | 51–53        | Belum ada rencana <i>baseline comparison</i>                                                                                 | Ditambahkan sub-bab 4.10 Baseline Comparison (Tabel 4.5) dengan 4 metode pembandingan (x-vector+PLDA, ECAPA-TDNN standar, Prototypical Network, openFEAT) dan metodologi <i>re-run</i> pada protokol identik.                   |
| 13 | 53–54        | Tidak ada uji signifikansi statistik                                                                                         | Ditambahkan sub-bab 4.11 Uji Signifikansi Statistik: 10 pengulangan per konfigurasi, <i>paired t-test/Wilcoxon</i> untuk Accuracy, <i>bootstrap</i> untuk EER, dengan koreksi Bonferroni.                                       |
| 14 | 56–60        | Link dalam Daftar Pustaka banyak tidak bisa diakses                                                                          | Disesuaikan atau dikroscek ulang untuk seluruh <i>link/DOI</i> di Daftar Pustaka.                                                                                                                                               |